Orientation et tri multimodal des demandeurs d'emploi par l'Intelligence Artificielle

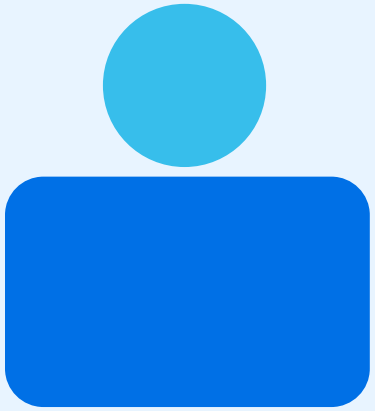
Théo Capitaine

14/10/2026

Atos

Repérer le chômage de longue durée sans laisser le modèle décider seul

Le cas d'usage : aider le conseiller, sans masquer une erreur grave



Une personne

risque de rester sans emploi
plus de 12 mois

SITUATION RÉELLE : CLASSE 2

LE MODÈLE

prédit un retour rapide

PRÉDICTION : CLASSE 0

ERREUR CRITIQUE

Le dossier peut passer sous le radar

Le conseiller garde la décision finale

Fil rouge : performance mesurée + escalade humaine + limites explicites

L’erreur critique transforme un dossier à risque en faux retour rapide

Toutes les erreurs ne se valent pas

CLASSE 0

Retour < 6 mois

CLASSE 1

Retour 6 à 12 mois

CLASSE 2

Risque > 12 mois

Situation réelle : classe 2 — prédite comme — **classe 0** — **DOSSIER NON PRIORISÉ**

Objectif : réduire ce risque sans automatiser la décision du conseiller.

Un même dossier combine données structurées, texte et cible

2 500 dossiers • 10 colonnes • une variable sensible isolée

NUMÉRIQUE

âge
ancienneté

CATÉGORIEL

diplôme •
métier
allocation •
géographie

TEXTE LIBRE

synthèse
d'entretien

SENSIBLE

nationalite_hor
s_ue

CIBLE

classe 0, 1 ou 2

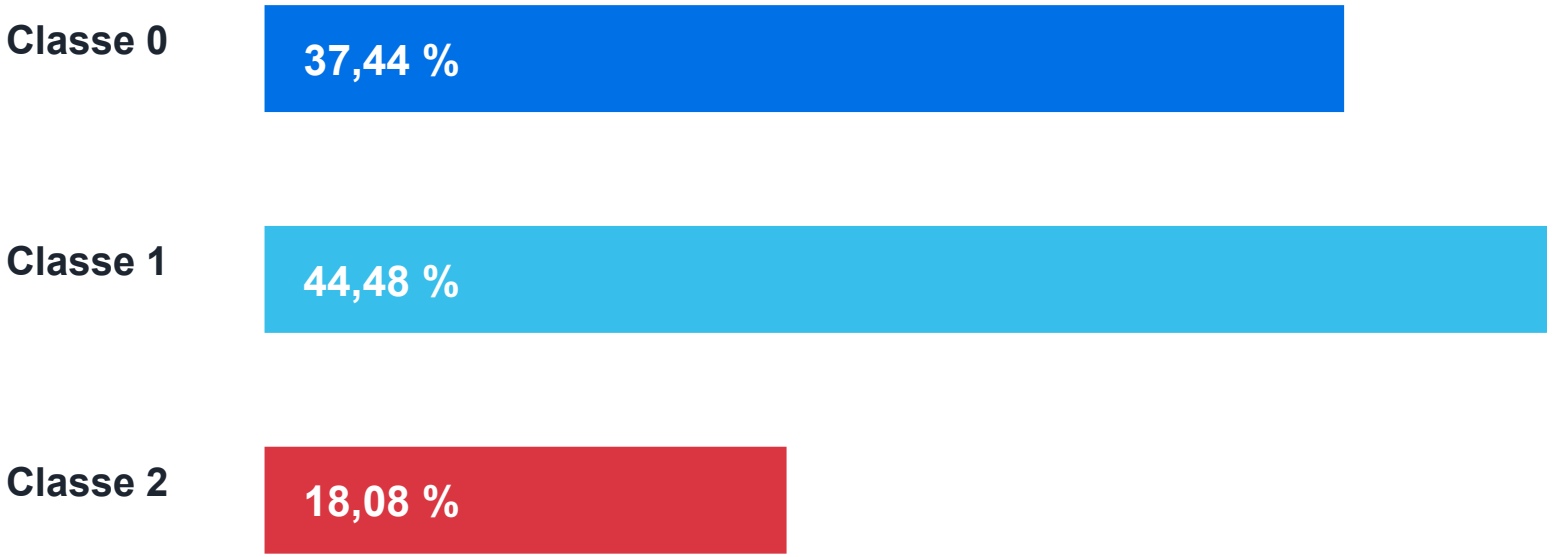
Limites à garder visibles

- classe 2 minoritaire
- texte peu diversifié
- proxys possibles

Retirer une variable sensible directe ne suffit pas à garantir l'absence de biais.

La classe 2 est minoritaire : 18,08 % des dossiers

Le déséquilibre et les proxys possibles guident la suite



À SURVEILLER

- valeurs manquantes modérées
- écarts liés à la nationalité
- proxys : âge, allocation, géographie, texte
- texte répétitif : sur-apprentissage

Les choix reposent sur l’OOF, avec une réserve sur le test

Le test final a été consulté dans une version antérieure : il n’est pas présenté comme totalement vierge



Ce que l’OOF limite

Les choix de modèle et de seuil ne sont pas fondés sur un seul split.

RÉSERVE

Test déjà consulté auparavant → lecture finale, pas preuve vierge

Prétraitements : imputation • encodages • TF-IDF • extraction du département INSEE

S1 : quel est le maximum avec toutes les variables ?

Référence expérimentale, pas choix final

S1 **Critère : performance maximale**

F1 macro	Rappel classe 2	Erreurs 2→0
0,708	**0,572**	**9**
validation croisée	validation croisée	sur le test

CE QUE CETTE OPTION APPORTE

- meilleur F1 des quatre scénarios
- mesure le plafond expérimental

CE QUI EMPÊCHE DE LA RETENIR SEULE

- utilise la variable sensible directe
- ne répond pas au compromis recherché

S2 : quel est le coût d’exclure la variable sensible directe ?

Le compromis retenu

S2

Critère : compromis performance / risque / usage

F1 macro	Rappel classe 2	Erreurs 2→0
0,681	0,558	10
−0,027 vs S1	−0,014 vs S1	sur le test

CE QUE CETTE OPTION APPORTE

- combine données structurées et texte
- exclut nationalite_hors_ue
- coût de performance mesuré

CE QUI EMPÊCHE DE LA RETENIR SEULE

- proxys toujours possibles
- charge de revue humaine à valider

S3 : que vaut la synthèse d’entretien seule ?

Un diagnostic utile, pas le choix final

S3

Critère : contribution du texte au repérage

F1 macro	Rappel classe 2	Erreurs 2→0
0,635	**0,661**	**12**
validation croisée	meilleur rappel	sur le test

CE QUE CETTE OPTION APPORTE

- meilleur rappel de la classe 2
- montre la valeur du texte

CE QUI EMPÊCHE DE LA RETENIR SEULE

- plus faible F1
- 12 erreurs critiques sur le test
- texte peu diversifié

S4 : que valent les données tabulaires seules ?

Un résultat à lire avec réserve

S4

Critère : valeur du tabulaire, sans conclure trop vite

F1 macro	Rappel classe 2	Erreurs 2→0
0,672	0,589	8
validation croisée	validation croisée	sur le test

CE QUE CETTE OPTION APPORTE

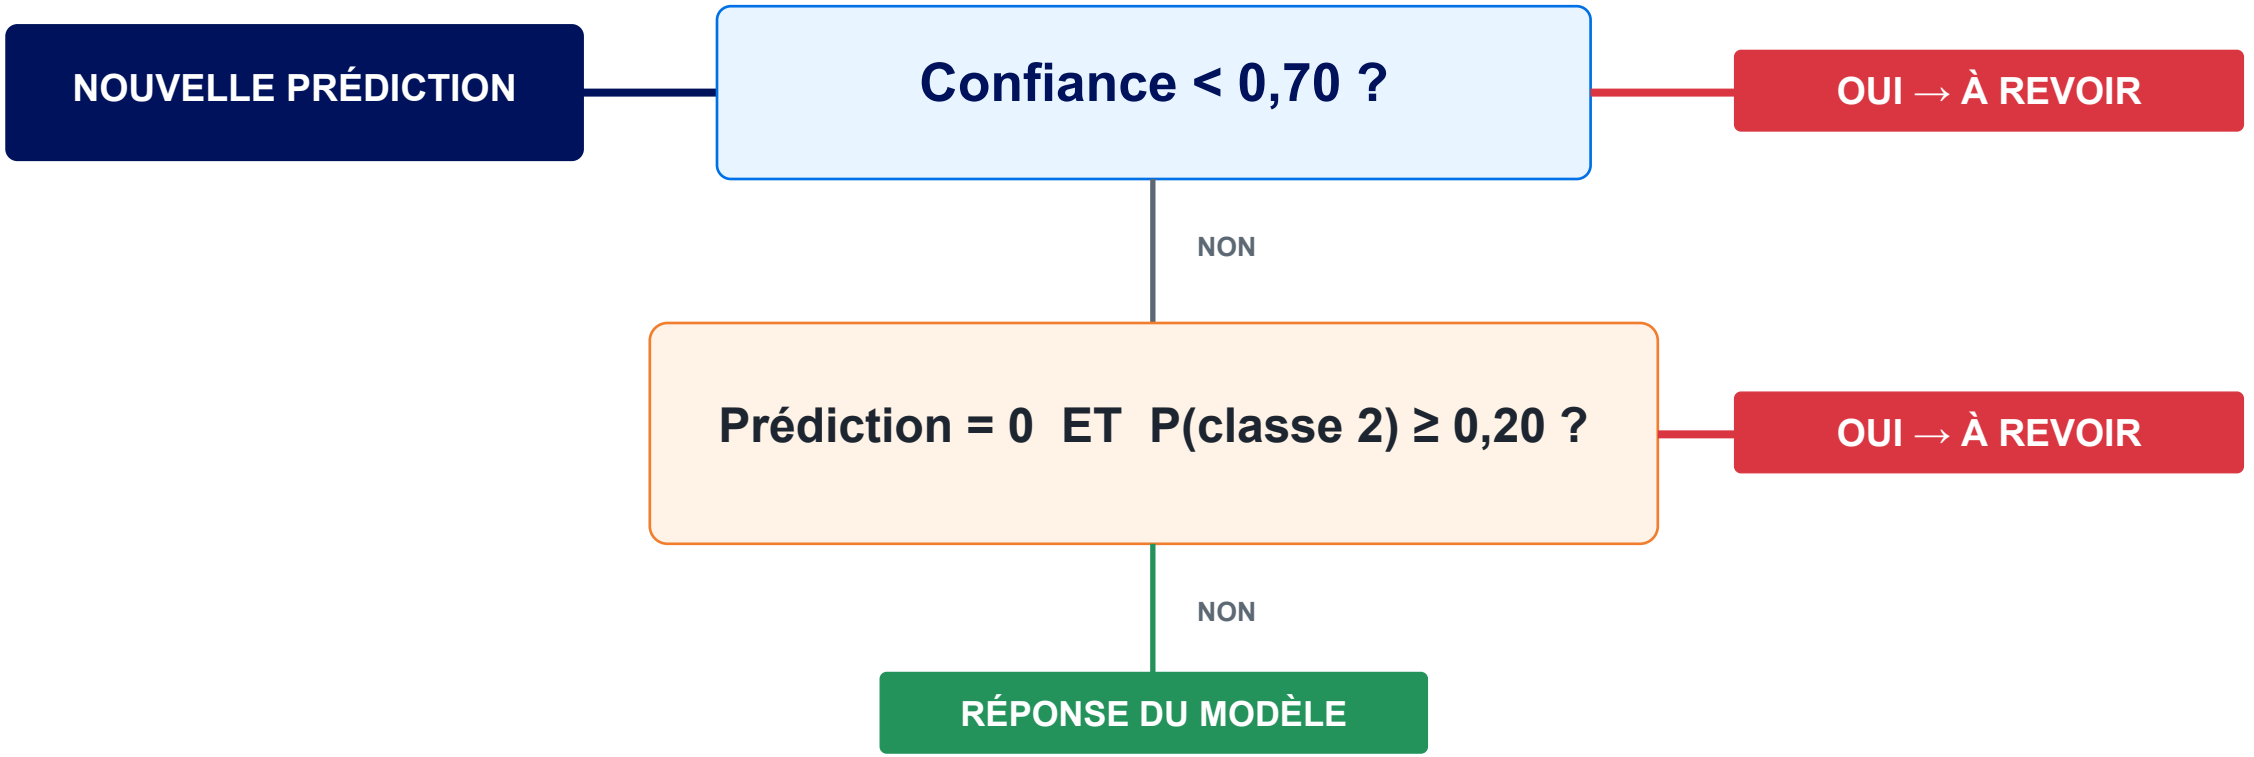
- 8 erreurs critiques sur 10 cas test
- score tabulaire compétitif

CE QUI EMPÊCHE DE LA RETENIR SEULE

- conserve actuellement la nationalité
- seulement 10 erreurs critiques au total
- pas équivalent à S2

La revue humaine se déclenche par une règle OU

La confiance est la probabilité la plus élevée du modèle, pas une certitude



Notebook : règle combinée évaluée (0,70 + garde-fou classe 2)

API actuelle : seuil simple de 0,55

La règle couvre davantage d’erreurs, mais oriente ~40 % des dossiers en revue

Choix sur OOF et lecture sur le test restent séparés

CHOIX SUR OOF

Seuil combiné
0,70

Couverture des erreurs critiques
≈ 72,5 %

≈ 40 % **des dossiers orientés vers une revue humaine**

Question de capacité : combien de dossiers un conseiller peut-il réellement revoir ?

LECTURE SUR LE TEST

8 / 10 **erreurs critiques signalées**

Deux erreurs critiques ne sont pas signalées.

Ce résultat ne signifie pas 80 % de rappel général de la classe 2.

Il ne prouve pas non plus que les erreurs signalées auraient été corrigées.

S2 est retenu : un coût connu pour exclure la variable sensible directe

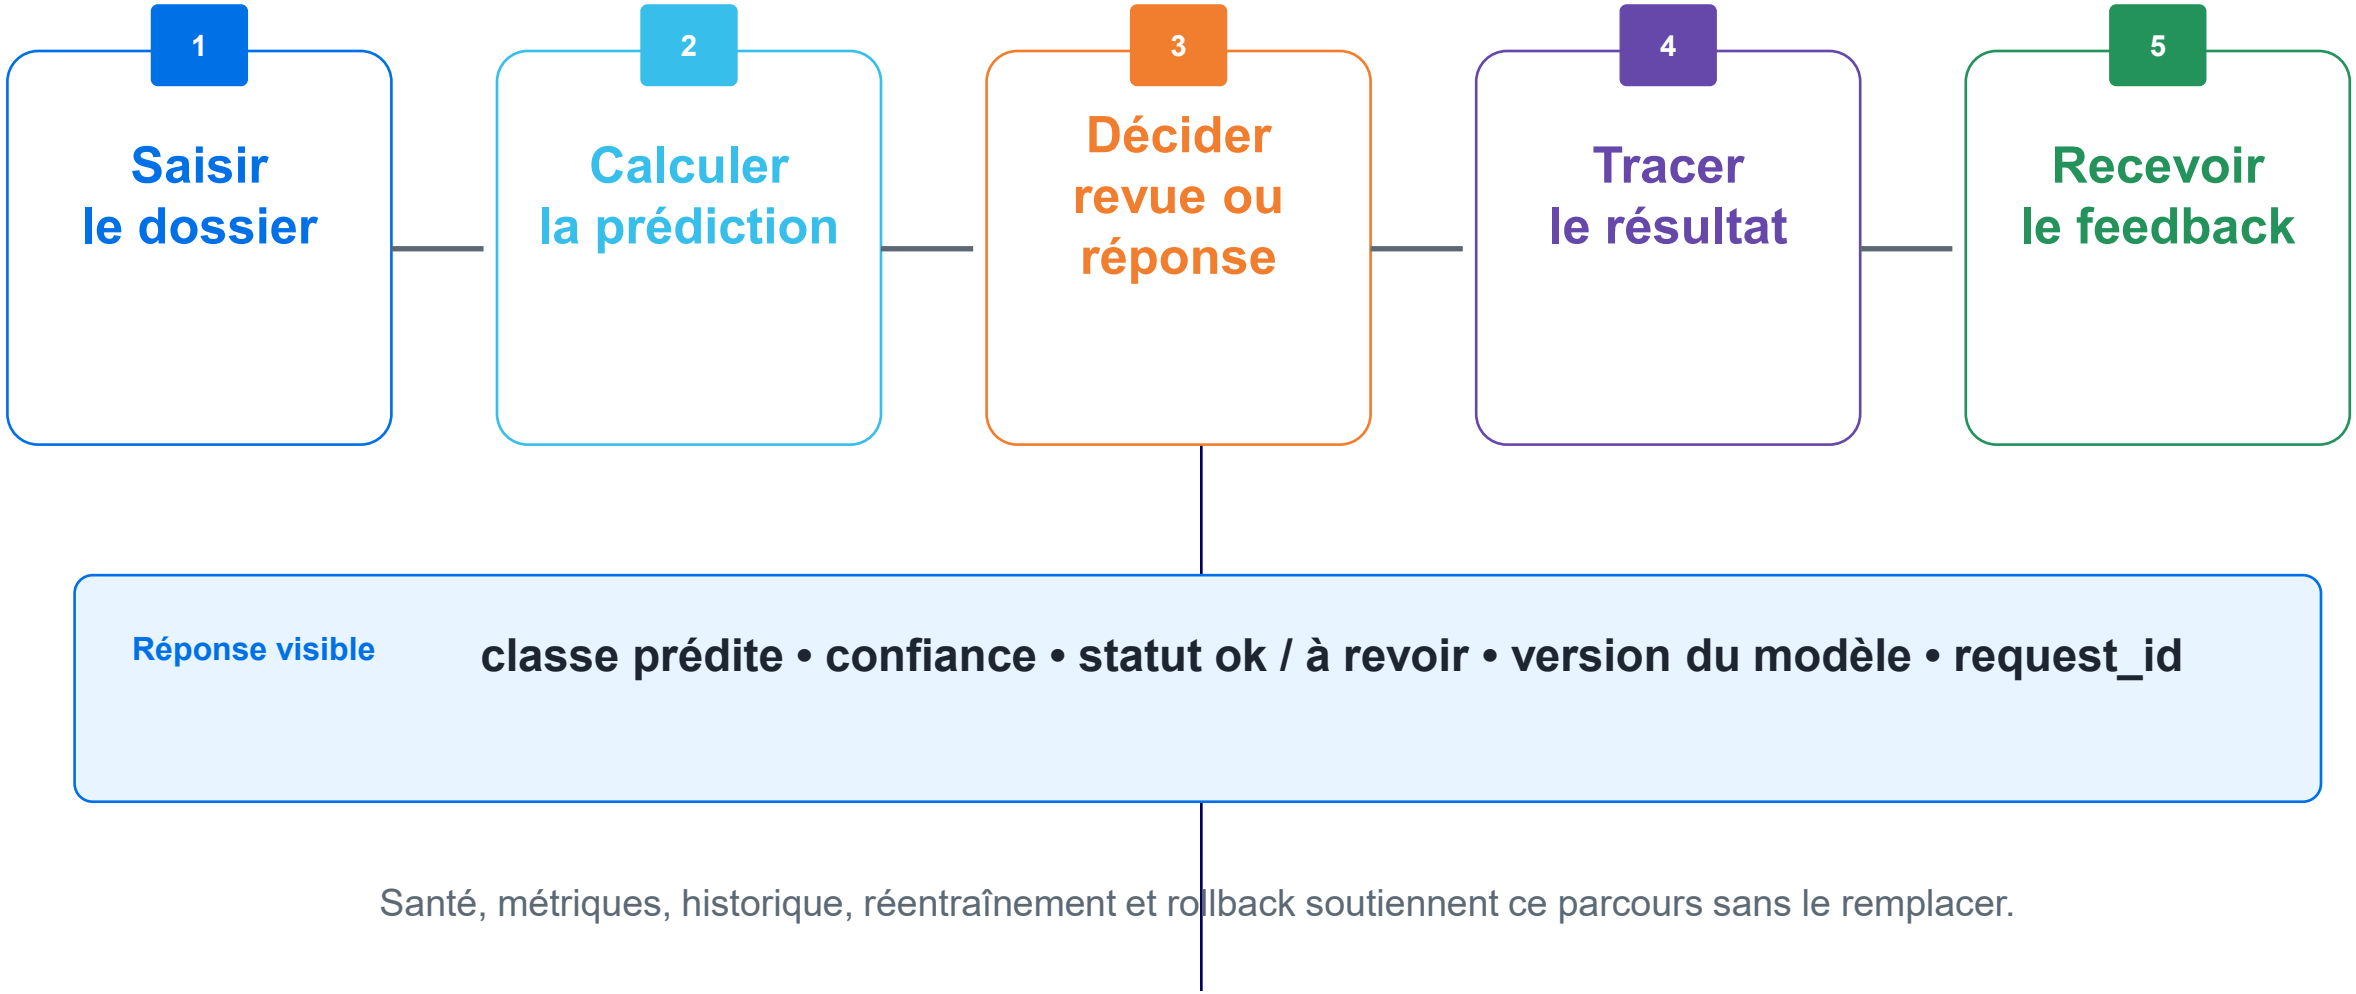
Le score maximal n'est pas le seul critère

S1	**F1 0,708**	Référence maximale	**Non retenu : variable sensible directe**
S2	**F1 0,681**	Tabulaire + texte	**RETENU : compromis mesuré**
S3	**F1 0,635**	Meilleur rappel cl. 2	**Diagnostic : valeur du texte**
S4	**F1 0,672**	8 erreurs 2→0	**Réserve : nationalité conservée, 10 cas**

Décision : S2 + revue humaine, avec capacité et intégration encore à valider.

Le service accompagne le parcours d’un dossier, de la saisie à la trace

Les endpoints restent en coulisse ; l’usage est la colonne vertébrale

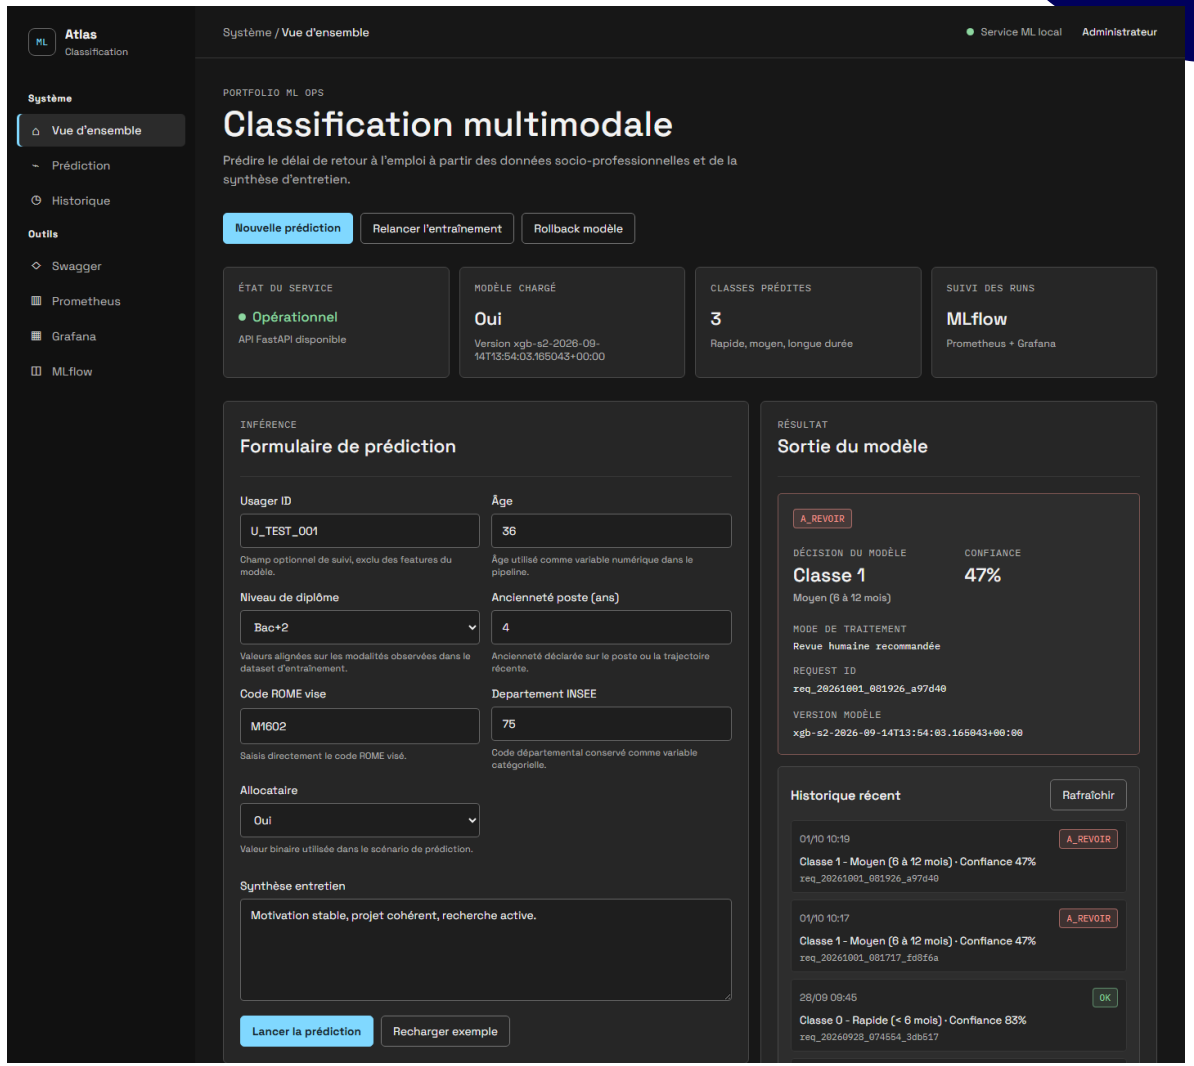


Le conseiller voit l’incertitude et sait quand reprendre la main

La classe prédite n’est jamais affichée seule

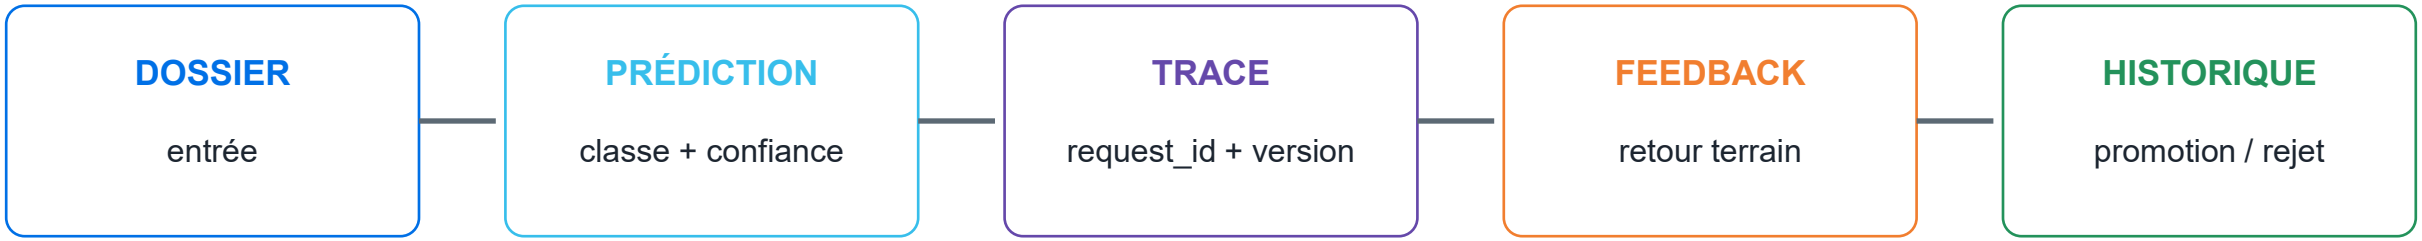
1. **Saisir un dossier**
2. **Lancer une prédiction**
3. **Lire classe + confiance**
4. **Voir le statut « à revoir »**
5. **Retrouver la trace**

La confiance = probabilité maximale du modèle, pas certitude.



Chaque prédiction reste rattachée à un modèle et à un identifiant

La traçabilité permet d'expliquer, comparer et revenir en arrière



CE QUI EST RÉELLEMENT TRACÉ

Inférence	Cycle modèle	Décision
request_id version du modèle	run MLflow paramètres et métriques	promotion ou rejet rollback disponible

Le monitoring sépare santé du service et comportement du modèle

Observer le service ne suffit pas à prouver la qualité du modèle

ACTIVITÉ

- volume de prédictions
- classes prédites
- événements de retrain

COMPORTEMENT

- distribution des confiances
- taux d’abstention

FIABILITÉ

- latence API
- erreurs HTTP
- disponibilité des cibles



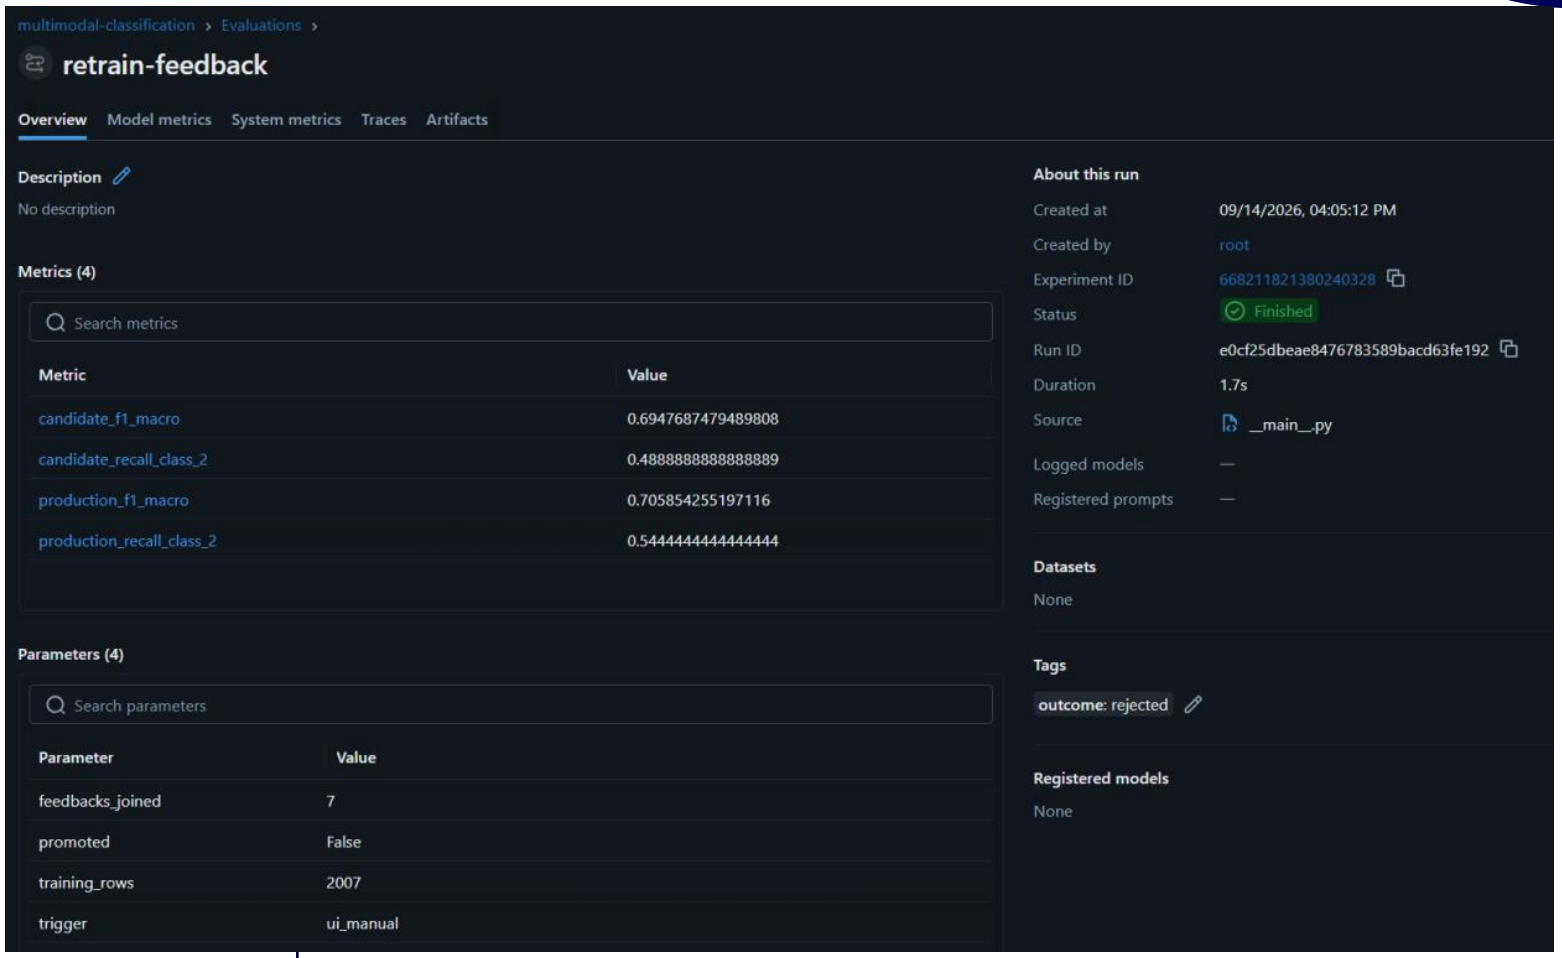
MLflow documente un candidat, mais “Finished” ne veut pas dire “promu”

Un run terminé peut encore être rejeté

POUR RECONSTRUIRE L’HISTOIRE

- paramètres d’entraînement
- métriques
- features utilisées
- artefacts du modèle
- identifiant du run
- décision de promotion ou rejet

FINISHED ≠ PROMU

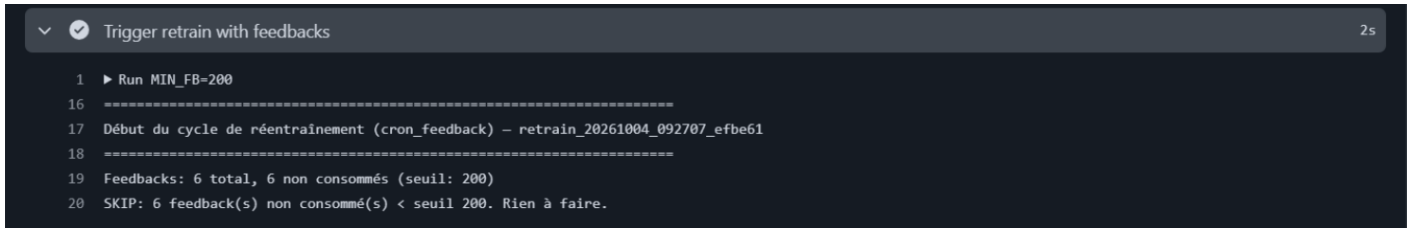


Cycle SKIP, pas un entraînement ni une promotion

Le cycle général existe ; la capture indique des feedbacks insuffisants

CYCLE GÉNÉRAL





PREUVE MONTRÉE

SKIP

feedbacks insuffisants

La capture ne montre ni entraînement, ni comparaison, ni promotion.

Le modèle actif reste inchangé.

Docker

La preuve porte sur l'orchestration, pas sur un déploiement en agence

Capture docker

- images construites
- services exportés / démarrés
- API, MLflow et retrain packagés
- orchestration locale reproductible

Ne prouve pas un déploiement réel
ni un dimensionnement cible.

```
#16 [mlflow] exporting to image
#16 unpacking to docker.io/library/multimodal-classification-mlflow:latest 25.2s done
#16 DONE 73.8s

#15 [retrain-cron] exporting to image
#15 unpacking to docker.io/library/multimodal-classification-retrain-cron:latest 25.2s done
#15 DONE 73.8s

#17 [api] exporting to image
#17 unpacking to docker.io/library/multimodal-classification-api:latest 25.2s done
#17 DONE 73.8s

#19 [api] resolving provenance for metadata file
#19 DONE 0.1s
#18 [mlflow] resolving provenance for metadata file
#18 DONE 0.1s
#20 [retrain-cron] resolving provenance for metadata file
#20 DONE 0.0s
 Image multimodal-classification-mlflow Built
 Image multimodal-classification-retrain-cron Built
 Image multimodal-classification-api Built
```

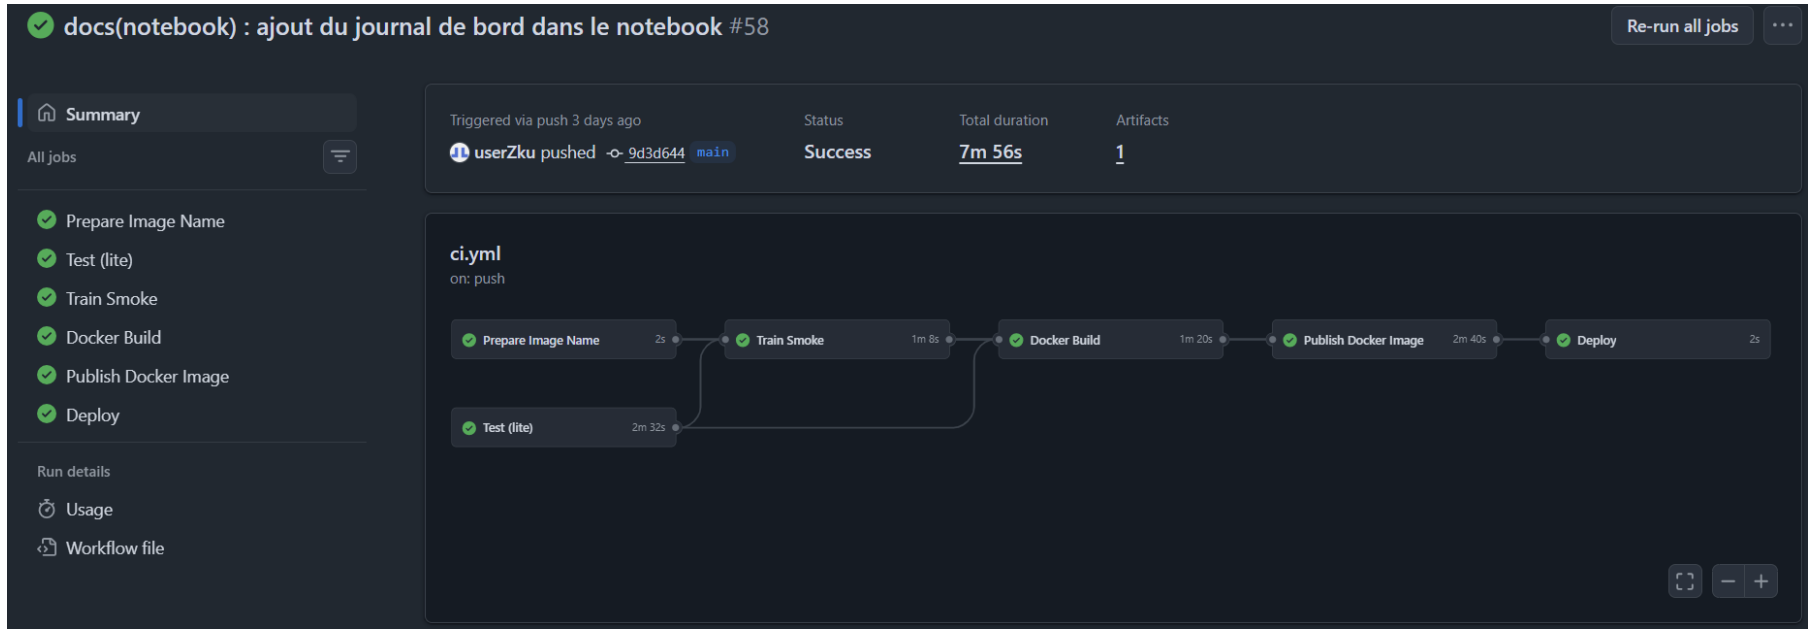
La CI/CD vérifie le parcours technique, pas la qualité métier du modèle

Le déploiement reste conditionnel au webhook

Tests + qualité — **Train smoke** — **Build Docker** — **Publier image** — **Déployer si configuré**

Train smoke = vérification minimale du parcours d'entraînement, pas preuve de qualité du modèle.

Sans webhook configuré, le déploiement peut être ignoré.



Les garde-fous réduisent le risque ; ils ne garantissent ni absence de biais ni conformité

Ces conditions doivent être surveillées avant et pendant tout usage

GARDE-FOUS OBSERVABLES

- nationalite_hors_ue exclue dans S2
- identifiant technique séparé
- prédictions journalisées
- cas incertains orientés vers revue
- proxys et texte à surveiller

CONDITIONS NON RÉSOLUES

- dataset de taille modérée
- classe 2 minoritaire
- faible diversité des textes
- capacité réelle de revue
- sécurité API à durcir
- biais indirects toujours possibles

L'exclusion d'une variable n'est ni une certification RGPD ni une preuve d'absence de biais.

Le prototype local est démontré ; l’intégration au SI reste à construire

Séparer la preuve actuelle des décisions d’industrialisation

DÉMONTRÉ LOCALEMENT

- **UI conseiller**
- **API**
- **Traçabilité**
- **Monitoring**

Démonstration locale, pas déploiement dans l’agence.

À CONSTRUIRE OU ARBITRER

- **Référentiel usagers** — intégration
- **Données minimisées** — règles et flux
- **Sécurité** — authentification / durcissement
- **Hébergement** — option à arbitrer
- **Latence** — charge et réseau à tester
- **CPU / RAM** — dimensionnement à valider

Cible : flux simples, données minimisées et capacité mesurée avant usage réel.

DÉCISION FINALE

S2 + revue humaine : un choix responsable à confirmer en conditions réelles

CHOIX

S2 sans variable sensible directe
+ règle de revue humaine

RAISON

Coût de performance mesuré
pour un compromis plus défendable

À VALIDER

Capacité ≈ 40 % • proxys • intégration SI
hébergement • sécurité • CPU / RAM

Le modèle signale. Le conseiller décide.

Atos