Orientation multimodale des demandeurs d'emploi par l'Intelligence Artificielle

Théo Capitaine

14/10/2026

Atos

Cas d’usage et cadre réglementaire

Conséquences réelles, supervision humaine et cadres à confirmer avec DPO/juridique

USAGE MÉTIER

- Le classement peut influer sur l’accompagnement proposé.
- Le conseiller confirme, corrige ou conteste la recommandation.
- Une procédure de contestation et une trace des décisions sont nécessaires.

CADRES À PRENDRE EN COMPTE

- AI Act : qualification « haut risque » dépend de la finalité et de l’usage effectif.
- RGPD : minimisation, justification, transparence et qualité des données.
- Retirer une variable ne vaut ni conformité ni certification.

L’erreur critique

Toutes les erreurs ne se valent pas

CLASSE 0	CLASSE 1	CLASSE 2
Retour < 6 mois	Retour 6 à 12 mois	Risque > 12 mois

Situation réelle : classe 2 — prédite comme — **classe 0** — **DOSSIER NON PRIORISÉ**

Objectif : réduire ce risque sans automatiser la décision du conseiller.

Un même dossier combine données structurées, texte et cible

2 500 dossiers • 10 colonnes • une variable sensible isolée

NUMÉRIQUE	CATÉGORIEL	TEXTE LIBRE	SENSIBLE	CIBLE
âge ancienneté	diplôme métier allocation géographie	synthèse d'entretien	nationalite_hors_ue	classe 0, 1 ou 2

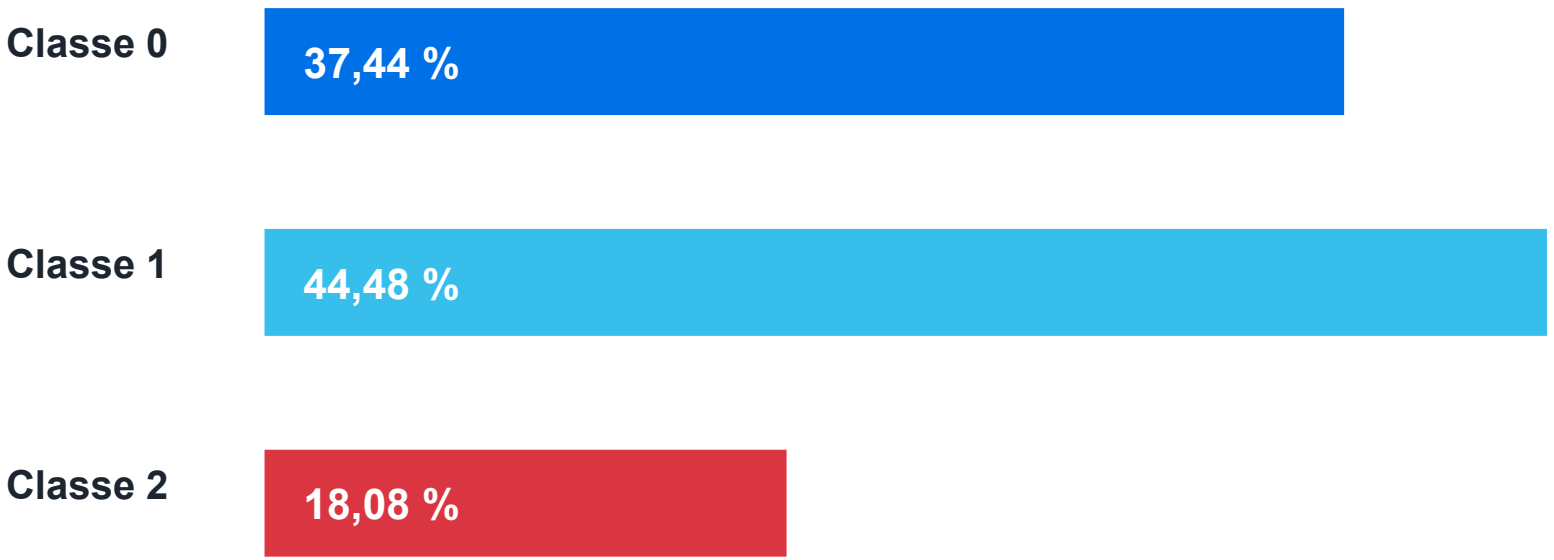
Limites à garder visibles

- classe 2 minoritaire
- texte peu diversifié
- proxys possibles

Retirer une variable sensible directe ne suffit pas à garantir l'absence de biais.

La classe 2 est minoritaire : 18,08 % des dossiers

Le déséquilibre et les proxys possibles guident la suite



À SURVEILLER

- valeurs manquantes modérées
- écarts liés à la nationalité
- proxys : allocation, géographie, texte
- texte répétitif : sur-apprentissage

Valeurs manquantes et imputation

Un blanc n'est ni automatiquement « Bac » au sens métier, ni « Sans diplôme »

MANQUANTS OBSERVÉS

- Âge : 4,88 % (122)
- Diplôme : 3,36 % (84)
- Synthèse : 3,24 % (81)
- Statut allocataire : 1,76 % (44)

TRAITEMENT ET LIMITE

- Pipeline courant : mode pour les catégories.
- Le mode du diplôme est « Bac » : 84 blancs sont donc imputés « Bac ».
- À tester : modalité « inconnu » ou indicateur de donnée manquante.
- À confirmer : sens du blanc dans la source.

Les choix reposent sur l'OOF, avec une réserve sur le test

Le test final a été consulté dans une version antérieure : il n'est pas présenté comme totalement vierge



Ce que l'OOF limite

Les choix de modèle et de seuil ne sont pas fondés sur un seul split.

RÉSERVE

Test déjà consulté auparavant → lecture finale, pas preuve vierge

Prétraitements : imputation • encodages • TF-IDF • extraction du département INSEE

Comparaison des modèles en validation croisée

Moyennes avant tuning final

Scénario	Logistic Reg.	Random Forest	XGBoost	LightGBM
S1 complet	0,665 / 0,669	0,653 / 0,710	0,708 / 0,572	0,686 / 0,608
S2 sans nationalité	0,660 / 0,674	0,645 / 0,694	0,681 / 0,558	0,664 / 0,591
S3 texte seul	0,635 / 0,661	0,635 / 0,661	0,635 / 0,661	0,635 / 0,661
S4 tabulaire seul	0,526 / 0,566	0,672 / 0,589	0,664 / 0,467	0,643 / 0,555

Lecture : dans S2, XGBoost a le meilleur F1 de la grille, mais Random Forest et Logistic Regression ont un meilleur rappel classe 2.

S1 : quel est le maximum avec toutes les variables ?

Référence expérimentale, pas choix final

S1 **Critère : performance maximale**

F1 macro	Rappel classe 2	Erreurs 2→0
0,708	**0,572**	**9**
validation croisée	validation croisée	sur le test

CE QUE CETTE OPTION APPORTE

- meilleur F1 des quatre scénarios
- mesure le plafond expérimental

CE QUI EMPÊCHE DE LA RETENIR SEULE

- utilise la variable sensible directe
- ne répond pas au compromis recherché

S2 : quel est le coût d'exclure la variable sensible directe ?

Le compromis retenu

S2

Critère : compromis performance / risque / usage

F1 macro	Rappel classe 2	Erreurs 2→0
0,681	0,558	10
−0,027 vs S1	−0,014 vs S1	sur le test

CE QUE CETTE OPTION APPORTE

- combine données structurées et texte
- exclut nationalite_hors_ue
- coût de performance mesuré

CE QUI EMPÊCHE DE LA RETENIR SEULE

- proxys toujours possibles
- charge de revue humaine à valider

S3 : que vaut la synthèse d'entretien seule ?

Un diagnostic utile

S3

Critère : contribution du texte au repérage

F1 macro	Rappel classe 2	Erreurs 2→0
0,635	**0,661**	**12**
validation croisée	meilleur rappel	sur le test

CE QUE CETTE OPTION APPORTE

- meilleur rappel de la classe 2
- montre la valeur du texte

CE QUI EMPÊCHE DE LA RETENIR SEULE

- plus faible F1
- 12 erreurs critiques sur le test
- texte peu diversifié

S4 : que valent les données tabulaires seules ?

Un résultat à lire avec réserve

S4 Critère : valeur du tabulaire, sans conclure trop vite

F1 macro	Rappel classe 2	Erreurs 2→0
0,672	0,589	8
validation croisée	validation croisée	sur le test

CE QUE CETTE OPTION APPORTE

- 8 erreurs critiques sur 10 cas test
- score tabulaire compétitif

CE QUI EMPÊCHE DE LA RETENIR SEULE

- conserve actuellement la nationalité
- seulement 10 erreurs critiques au total
- pas équivalent à S2

Résultats test de S2 + XGBoost

Accuracy 0,730 • F1 macro 0,704 • rappel classe 2 0,533 • ROC-AUC OVR macro 0,871

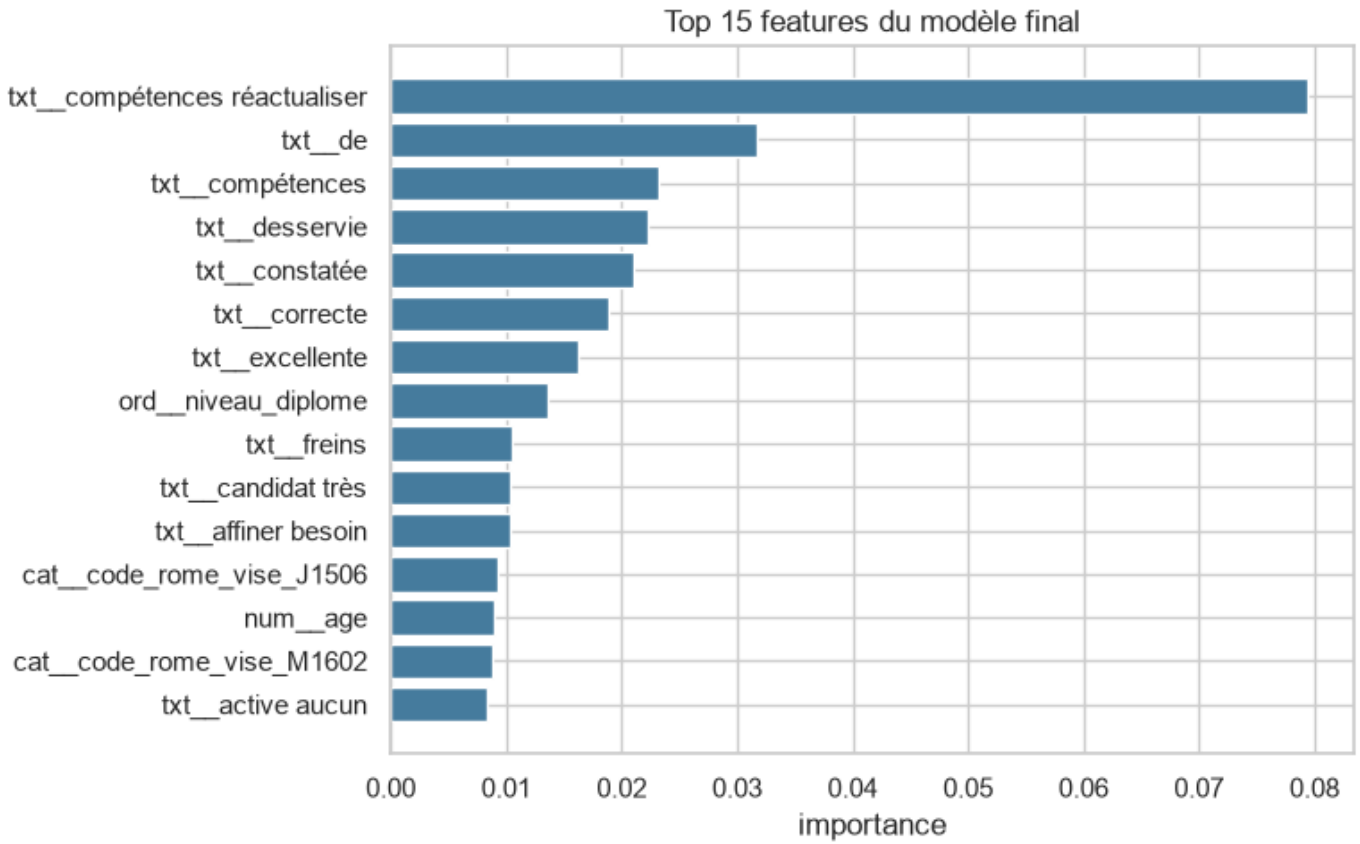
Réel \ Prédit	0	1	2
0	148	36	3
1	34	169	20
2	10	32	48

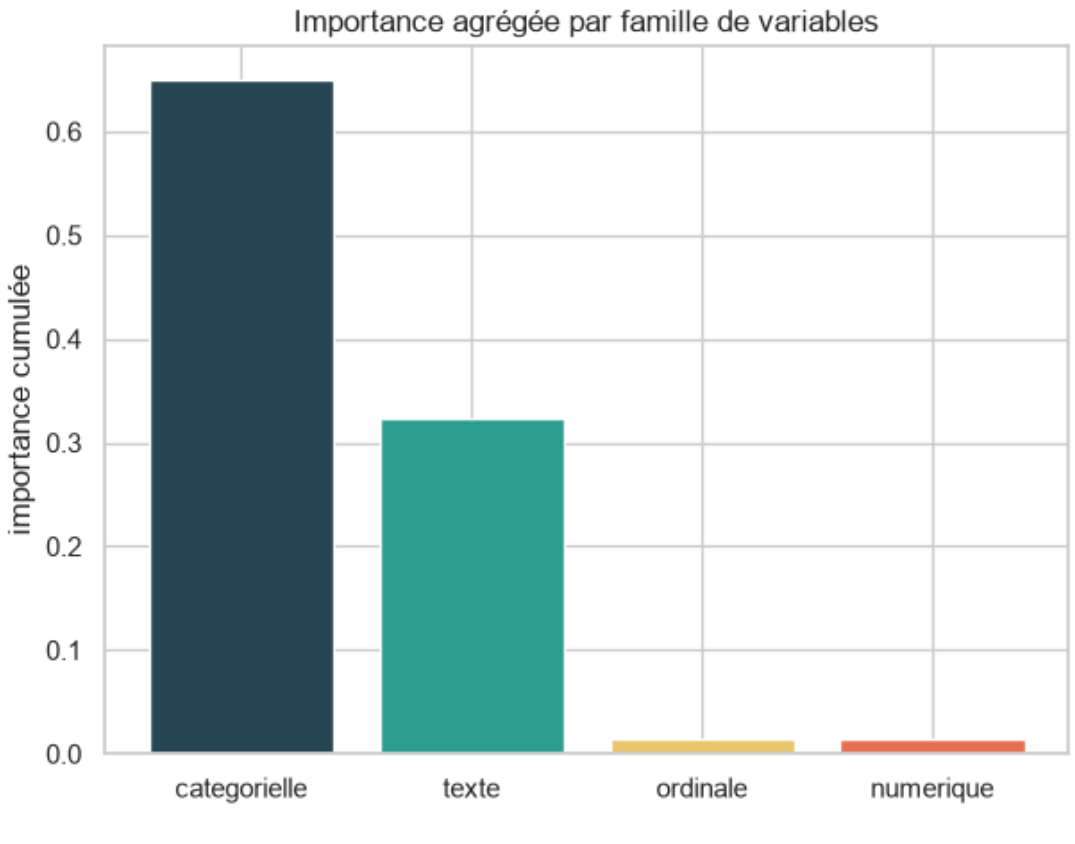
LECTURE DES ERREURS

- Classe 2 : 48/90 correctement détectés (53,3 %).
- 42/90 manqués au sens du rappel : 10 classés 0 et 32 classés 1.
- Erreur prioritaire 2→0 : 10/90 (11,1 %).
- Faux risques 0→2 : 3/187 (1,6 %), coût non mesuré.
- Réserve : le test n'est pas un holdout vierge.

Interprétation globale avec importance native XGBoost

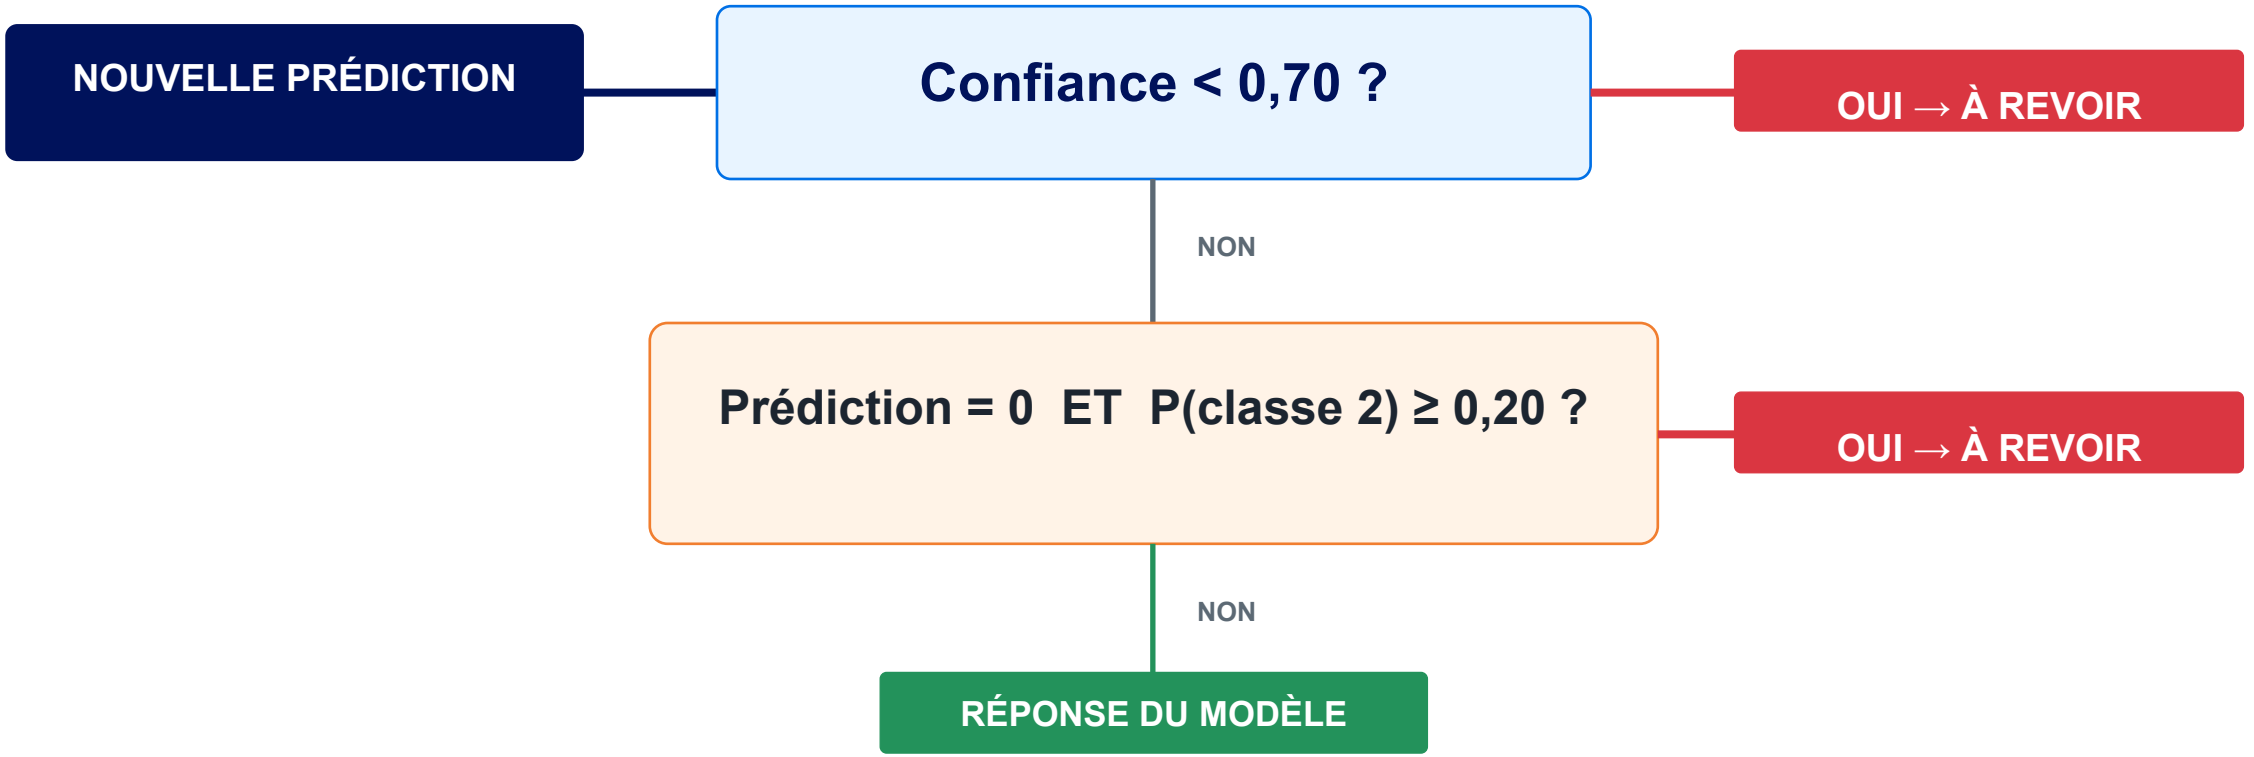
Séparer texte et variables structurées





La revue humaine se déclenche par une règle OU

La confiance est la probabilité la plus élevée du modèle, pas une certitude



Notebook : règle combinée évaluée (0,70 + garde-fou classe 2)

API actuelle : seuil simple de 0,55

La règle couvre davantage d'erreurs

Oriente ~40 % des dossiers en revue

CHOIX SUR OOF

Seuil combiné
0,70

Couverture des erreurs critiques
≈ 72,5 %

≈ 40 % **des dossiers orientés vers une revue humaine**

Question de capacité : combien de dossiers un conseiller peut-il réellement revoir ?

LECTURE SUR LE TEST

8 / 10 **erreurs critiques signalées**

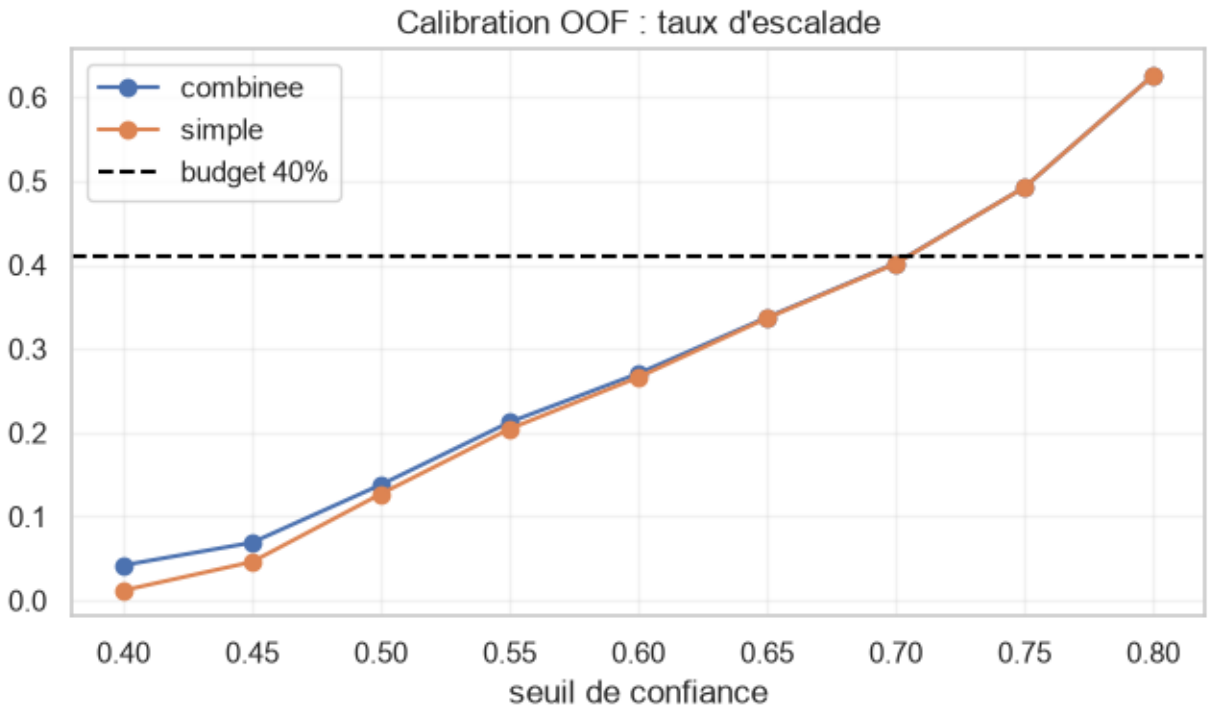
Deux erreurs critiques ne sont pas signalées.

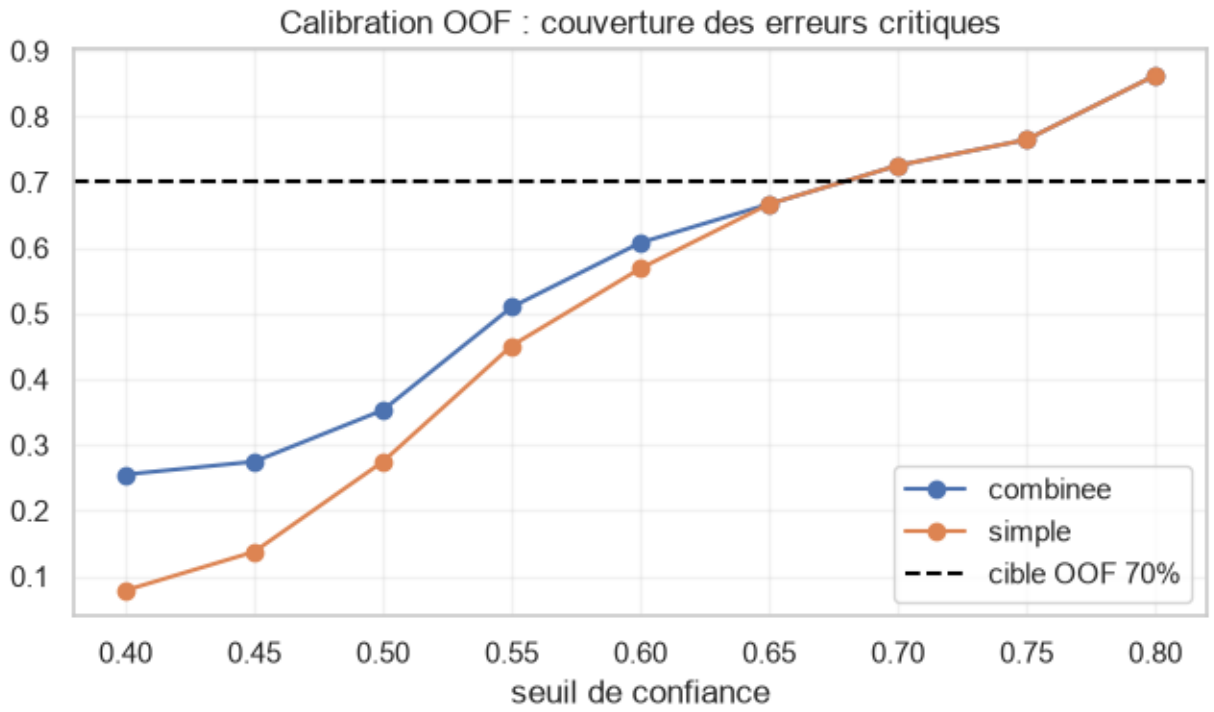
Ce résultat ne signifie pas 80 % de rappel général de la classe 2.

Il ne prouve pas non plus que les erreurs signalées auraient été corrigées.

Calibration des seuils

Taux d'escalade vs couvertures des erreurs cirtiques





Audit d’équité

Âge et nationalité

AUDIT ÂGE

- <30 ans : rappel classe 2 = 2/17 = 11,8 %.
- 50 ans et plus : 42/57 = 73,7 %.
- Âge conservé dans S2.
- À faire : ablation entraînée avec/sans âge.

AUDIT NATIONALITÉ

- Hors UE : 9/20 = 45,0 %.
- UE : 39/70 = 55,7 %.
- Retirer la nationalité ne prouve pas l’équité.
- Audit agrégé séparé, autorisé et encadré.

S2 est retenu : un coût connu pour exclure la variable sensible

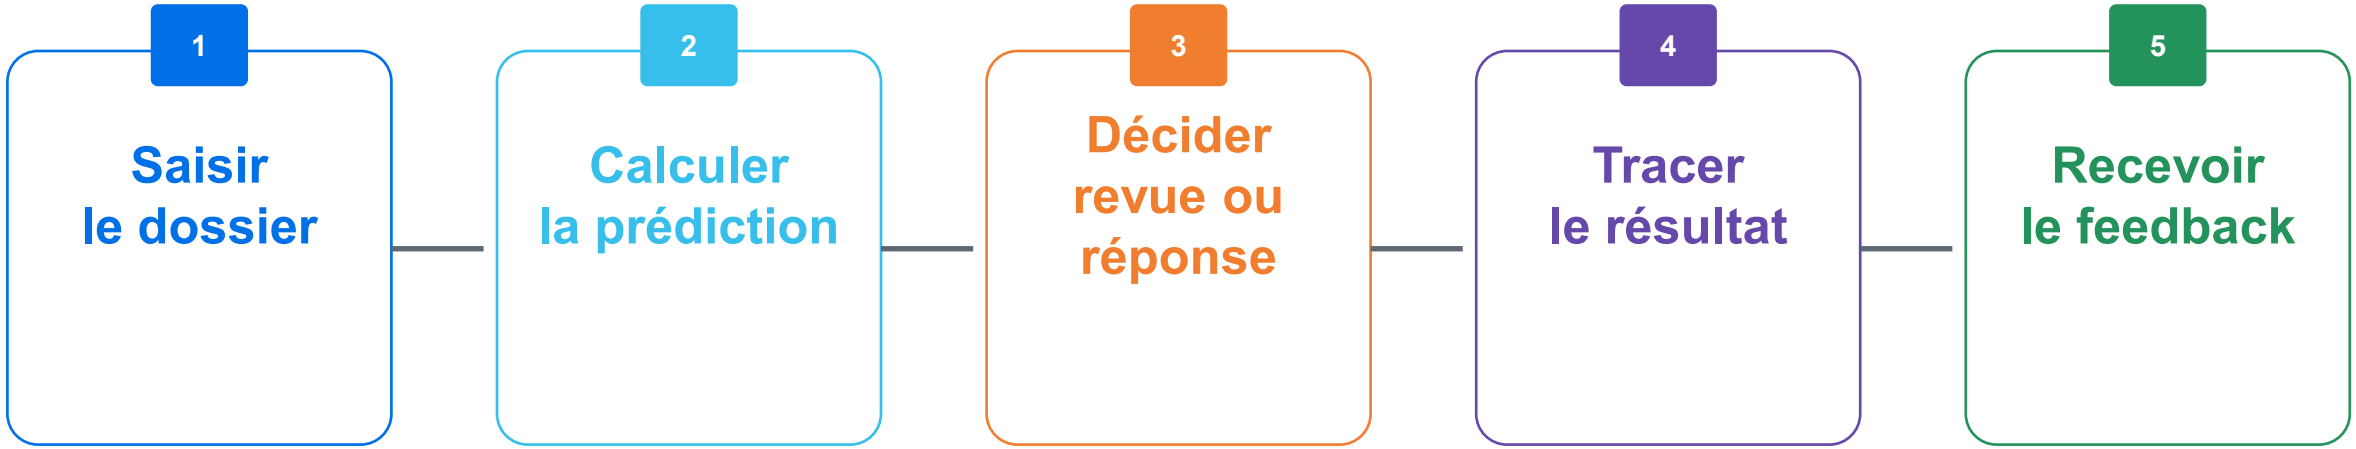
Le score maximal n'est pas le seul critère

S1	**F1 0,708**	Référence maximale	**Non retenu : variable sensible directe**
S2	**F1 0,681**	Tabulaire + texte	**RETENU : compromis mesuré**
S3	**F1 0,635**	Meilleur rappel cl. 2	**Diagnostic : valeur du texte**
S4	**F1 0,672**	8 erreurs 2→0	**Réserve : nationalité conservée, 10 cas**

Décision : S2 + revue humaine, avec capacité et intégration encore à valider.

Le service accompagne le parcours d'un dossier

De la saisie à la trace



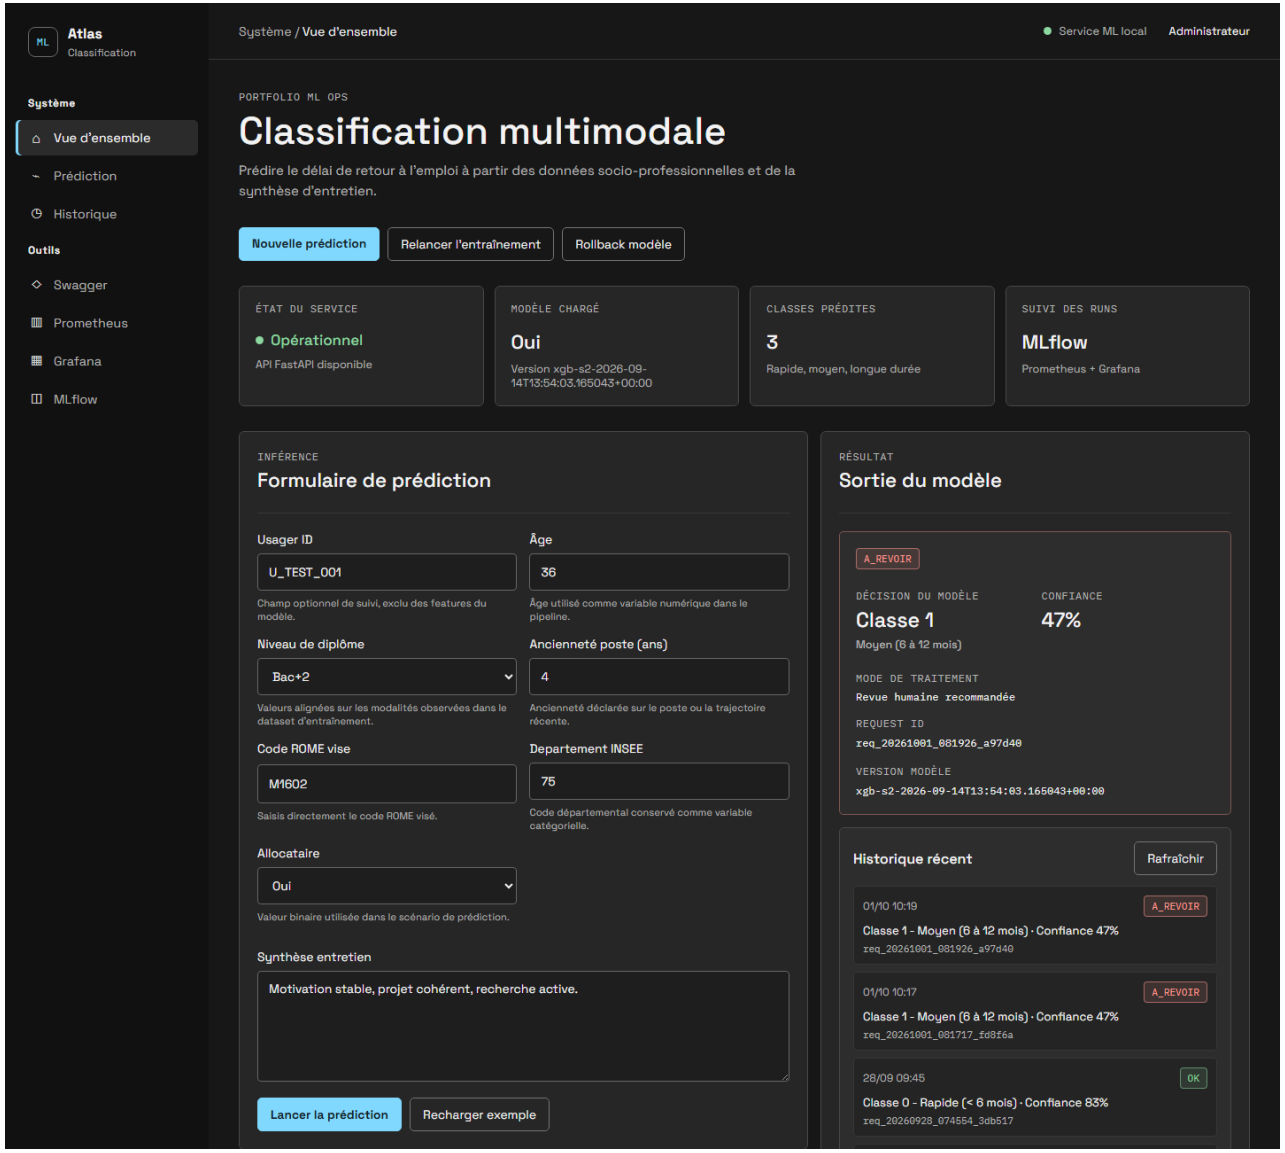
Réponse visible classe prédite • confiance • statut ok / à revoir • version du modèle • request_id

Santé, métriques, historique, réentraînement et rollback soutiennent ce parcours sans le remplacer.

L’interface du conseiller

1. Saisir un dossier
2. Lancer une prédiction
3. Lire classe + confiance
4. Voir le statut « à revoir »
5. Retrouver la trace

La confiance = probabilité maximale du modèle, pas certitude.



Feedback humain et label terrain

Ne pas réentraîner comme s'ils mesuraient la même chose

FEEDBACK HUMAIN

- Avis immédiat du conseiller.
- Annotation ou correction opérationnelle.
- Peut refléter expertise, règles locales et biais humains.
- Utile pour comprendre la revue, pas comme vérité future automatique.

LABEL TERRAIN

- Retour à l'emploi réellement observé.
- Label retardé de 6 à 12 mois.
- Peut être censuré ou incomplet.
- Source à définir et qualité à contrôler avant réentraînement.

Biais de sélection du feedback

Prévoir une collecte représentative avant toute boucle d'amélioration

Dossiers surtout incertains / complexes

Feedback observé non représentatif

Risque de renforcer le filtre initial

GARDE-FOUS DE COLLECTE

- Échantillon de contrôle parmi les dossiers non signalés.
- Collecte de labels selon un plan représentatif.
- Analyses globales et par groupes avant réentraînement.

Le monitoring

Prometheus / Grafana

ACTIVITÉ

- volume de prédictions
- classes prédites
- événements de retrain

COMPORTEMENT

- distribution des confiances
- taux d’abstention

FIABILITÉ

- latence API
- erreurs HTTP
- disponibilité des cibles



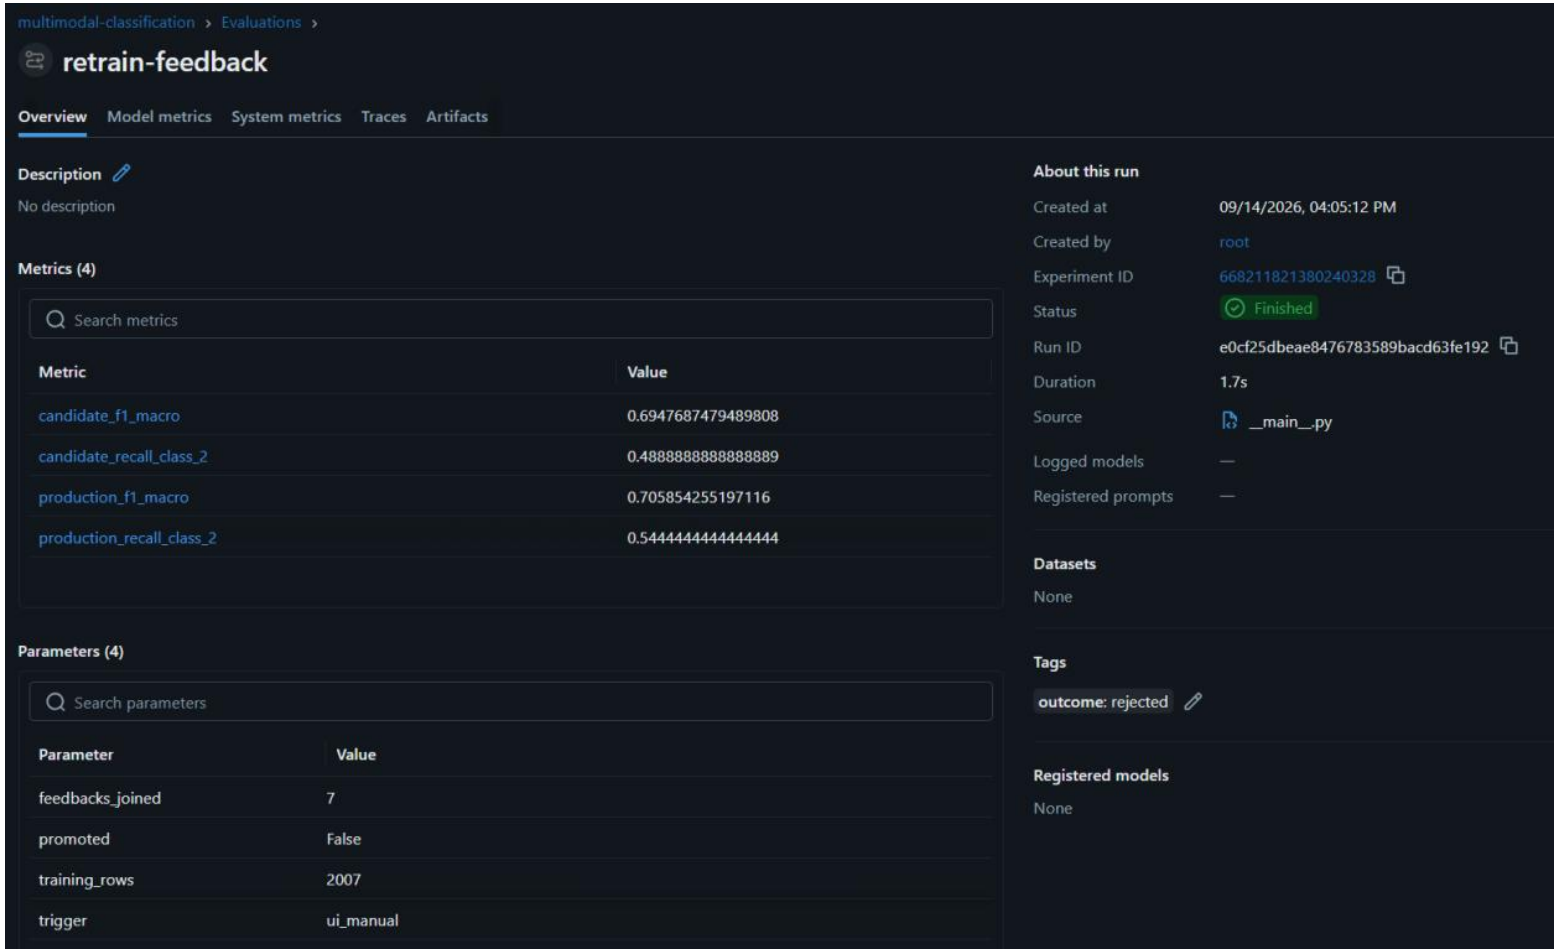
MLflow documente un candidat

Un run terminé peut encore être rejeté

POUR RECONSTRUIRE L'HISTORIQUE

- paramètres d'entraînement
- métriques
- features utilisées
- artefacts du modèle
- identifiant du run
- décision de promotion ou rejet

FINISHED ≠ PROMU



Cycle général de réentrainement

la capture indique des feedbacks insuffisants

CYCLE GÉNÉRAL



Trigger retrain with feedbacks 2s

```
1  ▶ Run MIN_FB=200
16 ================================================================
17 Début du cycle de réentraînement (cron_feedback) — retrain_20261004_092707_efbe61
18 ================================================================
19 Feedbacks: 6 total, 6 non consommés (seuil: 200)
20 SKIP: 6 feedback(s) non consommé(s) < seuil 200. Rien à faire.
```

Docker

Orchestration et images

Capture docker

- images construites
- services exportés / démarrés
- API, MLflow et retrain packagés
- orchestration locale reproductible

Ne prouve pas un déploiement réel
ni un dimensionnement cible.

```
#16 [mlflow] exporting to image
#16 unpacking to docker.io/library/multimodal-classification-mlflow:latest 25.2s done
#16 DONE 73.8s

#15 [retrain-cron] exporting to image
#15 unpacking to docker.io/library/multimodal-classification-retrain-cron:latest 25.2s done
#15 DONE 73.8s

#17 [api] exporting to image
#17 unpacking to docker.io/library/multimodal-classification-api:latest 25.2s done
#17 DONE 73.8s

#19 [api] resolving provenance for metadata file
#19 DONE 0.1s
#18 [mlflow] resolving provenance for metadata file
#18 DONE 0.1s
#20 [retrain-cron] resolving provenance for metadata file
#20 DONE 0.0s
 Image multimodal-classification-mlflow Built
 Image multimodal-classification-retrain-cron Built
 Image multimodal-classification-api Built
```

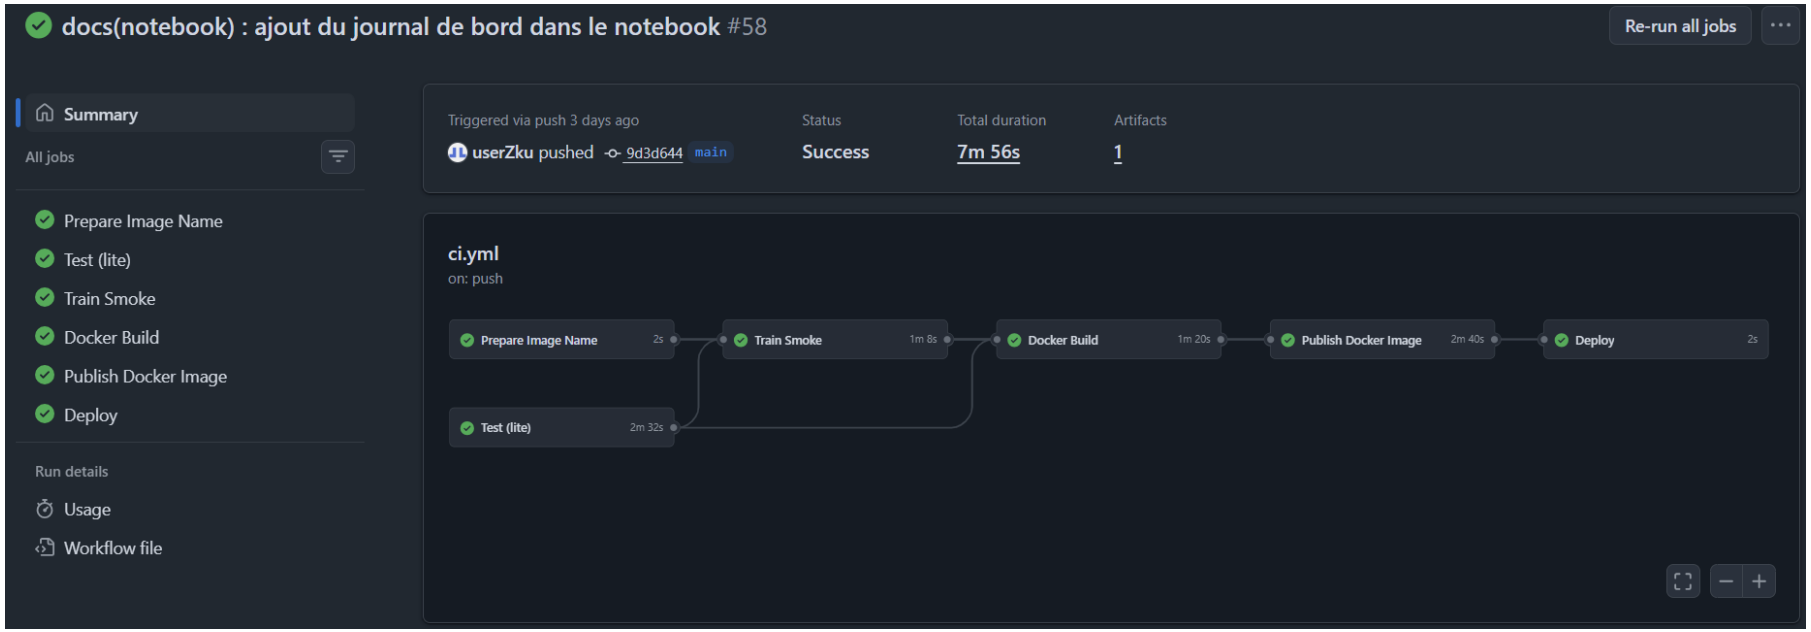
CI/CD vérifie le parcours technique

Le déploiement reste conditionnel au webhook

Tests + qualité — **Train smoke** — **Build Docker** — **Publier image** — **Déployer si configuré**

Train smoke = vérification minimale du parcours d'entraînement, pas preuve de qualité du modèle.

Sans webhook configuré, le déploiement peut être ignoré.



Prototype local démontré

Intégration au SI reste à construire

DÉMONTRÉ LOCALEMENT

- **UI conseiller**
- **API**
- **Traçabilité**
- **Monitoring**

Démonstration locale, pas de déploiement

À CONSTRUIRE OU ARBITRER

- **Référentiel usagers** — intégration
- **Données minimisées** — règles et flux
- **Sécurité** — authentification / durcissement
- **Hébergement** — option à arbitrer
- **Latence** — charge et réseau à tester
- **CPU / RAM** — dimensionnement à valider

Cible : flux simples, données minimisées et capacité mesurée avant usage réel.

DÉCISION FINALE

S2 + revue humaine : un choix responsable à confirmer en conditions réelles

CHOIX

S2 + XGBoost
+ règle de revue humaine

RAISON

Coût de performance mesuré pour un compromis plus défendable

À VALIDER

Capacité ≈ 40 % • proxys • intégration SI hébergement • sécurité • CPU / RAM

Le modèle signale. Le conseiller décide.

Atos