Classification multimodale



Le problème métier

Toutes les erreurs ne se valent pas

- Classe 0 | Retour rapide : < 6 mois
- Classe 1 | Retour intermédiaire : 6 à 12 mois
- Classe 2 | Risque longue durée : > 12 mois

ERREUR CRITIQUE

Situation réelle : classe 2
Prédiction : classe 0

Priorité : détecter les cas qui risquent de passer sous le radar

Les données combinent tabulaire, texte et variable sensible

2 500 dossiers • 10 colonnes

Numérique
âge, ancienneté

Catégoriel
diplôme, métier, allocation, géographie

Texte libre
synthèse d'entretien

Sensible
nationalite_hors_ue

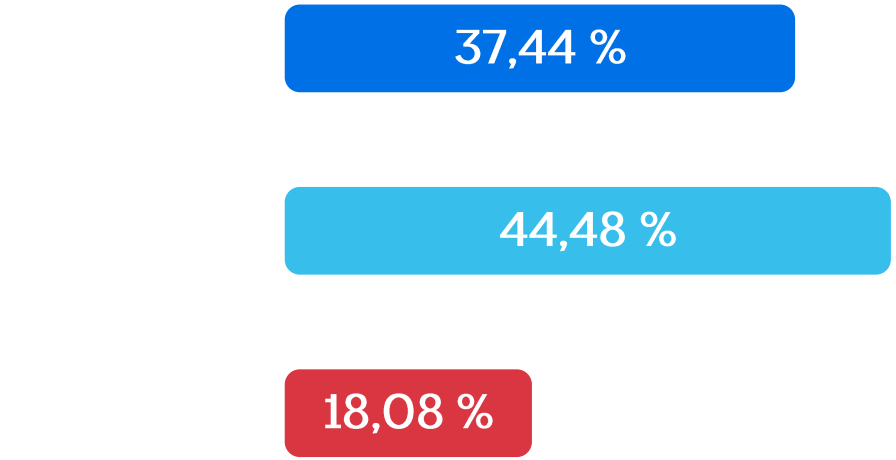
Cible
classe 0, 1 ou 2

Un même dossier alimente plusieurs modalités, mais la variable sensible reste isolée.

L’EDA révèle le déséquilibre et les risques de biais

La qualité des données guide la modélisation

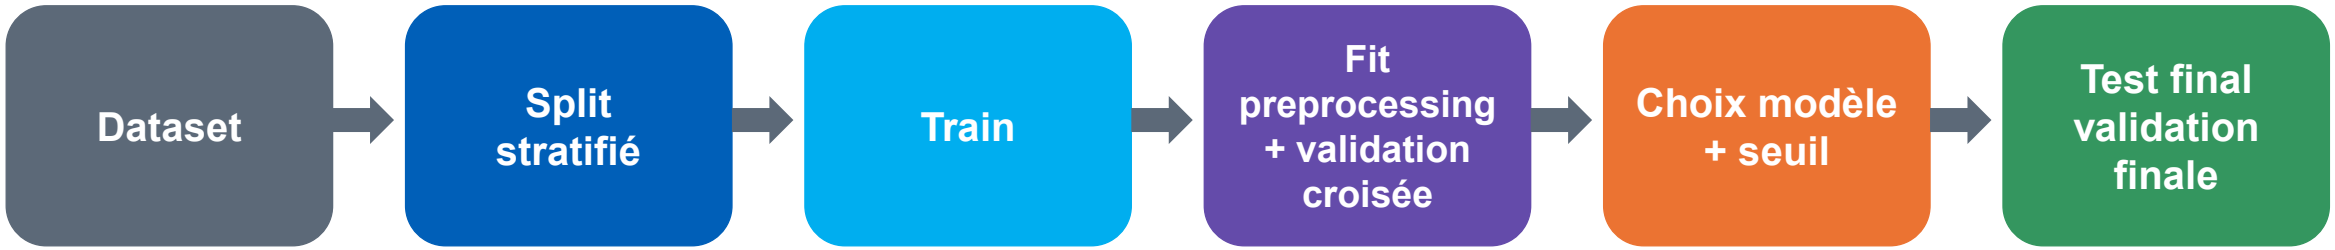
- Classe 2 minoritaire : 18,08 %
- Valeurs manquantes modérées
- Écarts liés à la nationalité
- Proxys possibles : âge, allocation, géographie, texte
- Texte peu diversifié : risque de sur-apprentissage



À surveiller : proxies et formulations répétitives

Le protocole OOF limite la fuite, avec une réserve explicitée

Les choix sont fondés sur le train et les prédictions out-of-fold



Imputation • encodage ordinal • one-hot encoding • TF-IDF • extraction du département INSEE

Quatre scénarios séparent performance et conformité

S1 est la référence expérimentale, S2 le candidat de production

- S1 — Multimodal complet
  Meilleur score avec toutes les variables
- S2 — Sans variable sensible
  Coût de l’exclusion de la nationalité
- S3 — Texte seul
  Valeur de la synthèse d’entretien
- S4 — Tabulaire seul
  Valeur des données structurées

Une grille de métriques relie score, risque et exploitabilité

Aucune métrique unique ne suffit

Performance globale

- Équilibre entre les trois classes et qualité du classement probabiliste.

Risque métier

- Capacité à identifier les situations longues et éviter le faux rassurant.

Opérations

- Compatibilité avec un entretien et coût des scénarios.

S2 n’est pas le score maximal, mais le compromis retenu

Comparaison des quatre options sur performance, risque critique et rôle dans la décision

Option	Configuration	F1 macro	Rappel cl. 2	Erreurs 2→0	Interprétation
S1	Complet	0,708	0,572	9	Meilleur F1 ; référence expérimentale, mais utilise la variable sensible directe.
S2	Sans sensible	0,681	0,558	10	Coût mesuré ; option retenue pour exclure la variable sensible directe.
S3	Texte seul	0,635	0,661	12	Meilleur rappel classe 2 ; utile comme diagnostic, mais davantage d’erreurs critiques.
S4	Tabulaire	0,672	0,589	8	Meilleur compte sur 10 cas ; réserve majeure : conserve actuellement la nationalité.

Lecture : les écarts d’erreurs critiques reposent sur seulement 10 cas ; ils ne suffisent pas, seuls, à trancher.

Le prix de la décision éthique est mesuré et assumé

Exclure nationalite_hors_ue réduit légèrement les performances

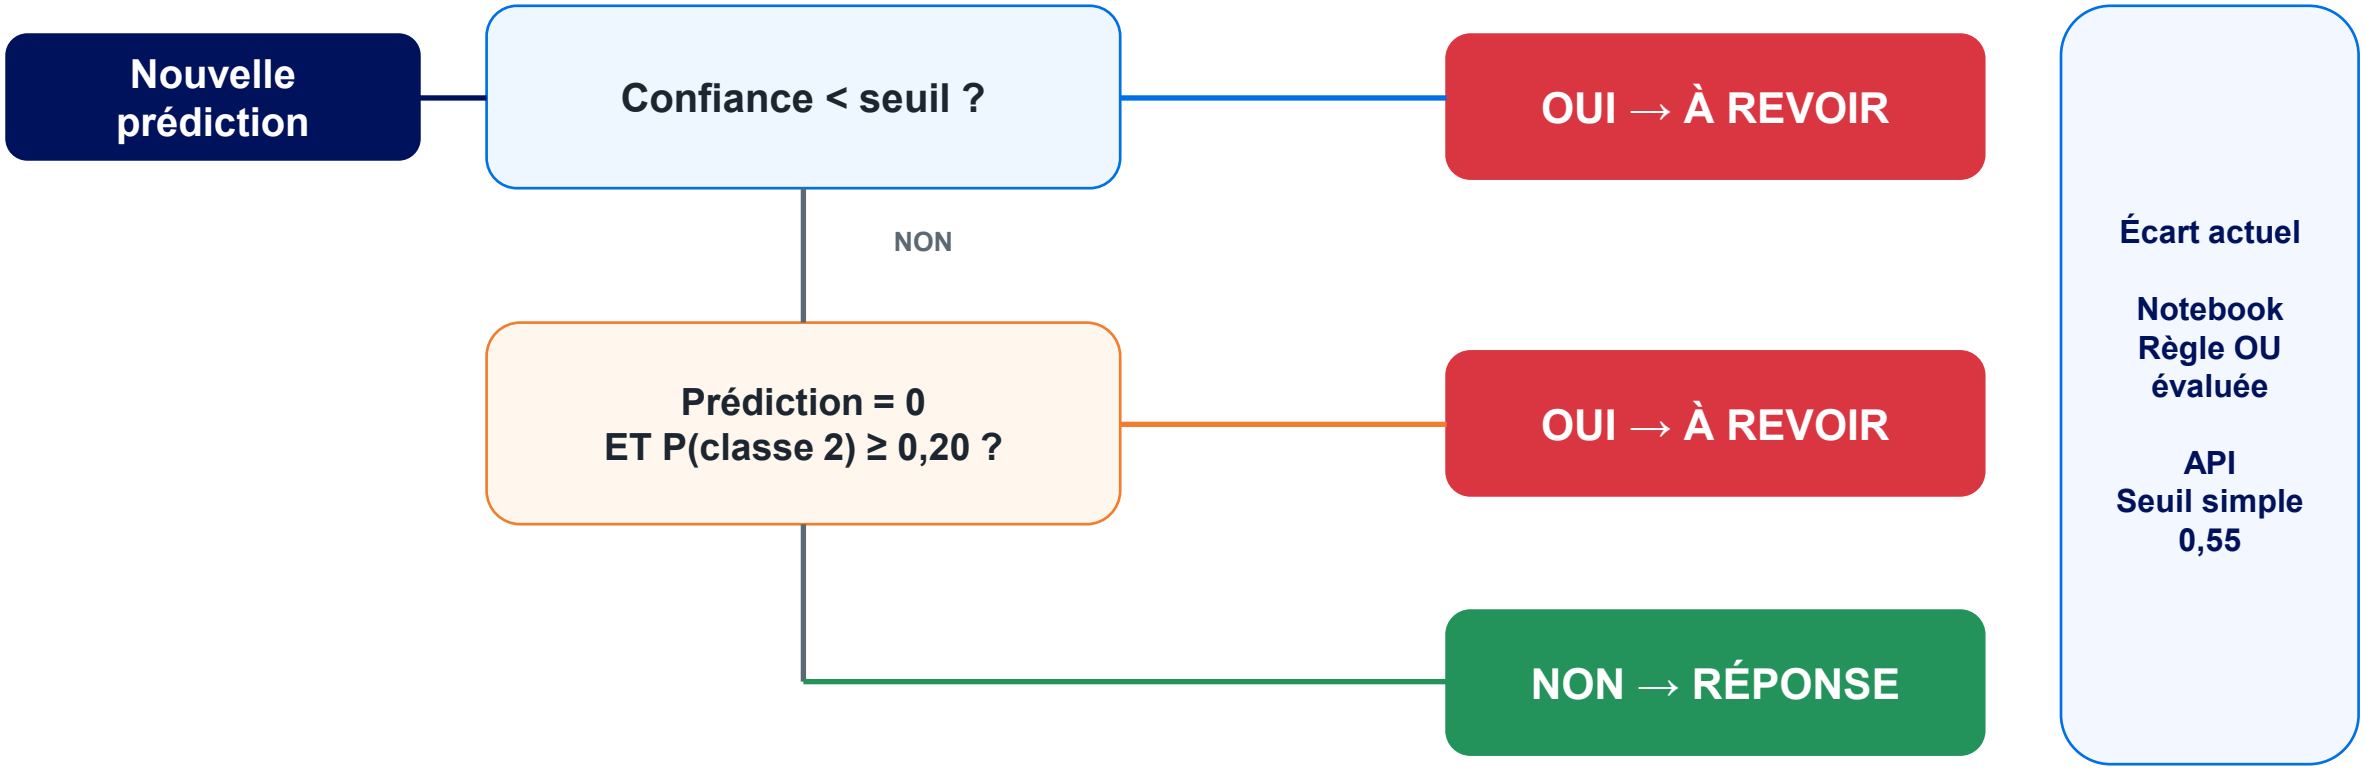
DÉCISION

- F1 macro : 0,708 → 0,681 | Δ = −0,027
- Recall classe 2 : 0,572 → 0,558 | Δ = −0,014

- « Je privilégie l'exclusion de la variable sensible directe, malgré une baisse mesurée de performance. Cela ne garantit pas l'absence de proxys. »

La politique d'escalade est une règle OU

Le notebook évalue la règle combinée ; l'API actuelle utilise encore le seuil simple de 0,55



Le seuil réduit le risque, sous contrainte de capacité

Résultats OOF pour choisir la politique, puis lecture séparée sur le test

CHOIX SUR OOF

Seuil combiné
0,70

Couverture des erreurs
≈ 72,5 %

Part des dossiers orientés vers la revue : ≈ 40 %

LECTURE SUR LE TEST

8 erreurs critiques signalées sur 10

Ce n'est pas 80 % de rappel général. Le dénominateur est de 10 cas.

Question ouverte : peut-on traiter environ 40 % des dossiers en revue ?

Je choisis S2 : un coût connu, une variable sensible directe exclue

Le score maximal n'est pas le seul critère de décision

	Avantage	Coût ou limite	Décision
S1	F1 maxi : 0,708	Variable sensible directe	Référence
S2	**Tabulaire + texte**	**F1 −0,027 ; revue à valider**	**RETENUE**
S3	Rappel cl. 2 : 0,661	12 erreurs critiques	Diagnostic
S4	8 erreurs critiques	Conserve la nationalité ; 10 cas	Réserve forte

Message central : je ne retiens pas le score maximal ; je choisis une solution sans variable sensible directe, avec un coût connu et une revue humaine dont la capacité reste à valider.

L’API transforme le pipeline en contrat de service

FastAPI expose la prédiction, la traçabilité et le cycle de vie

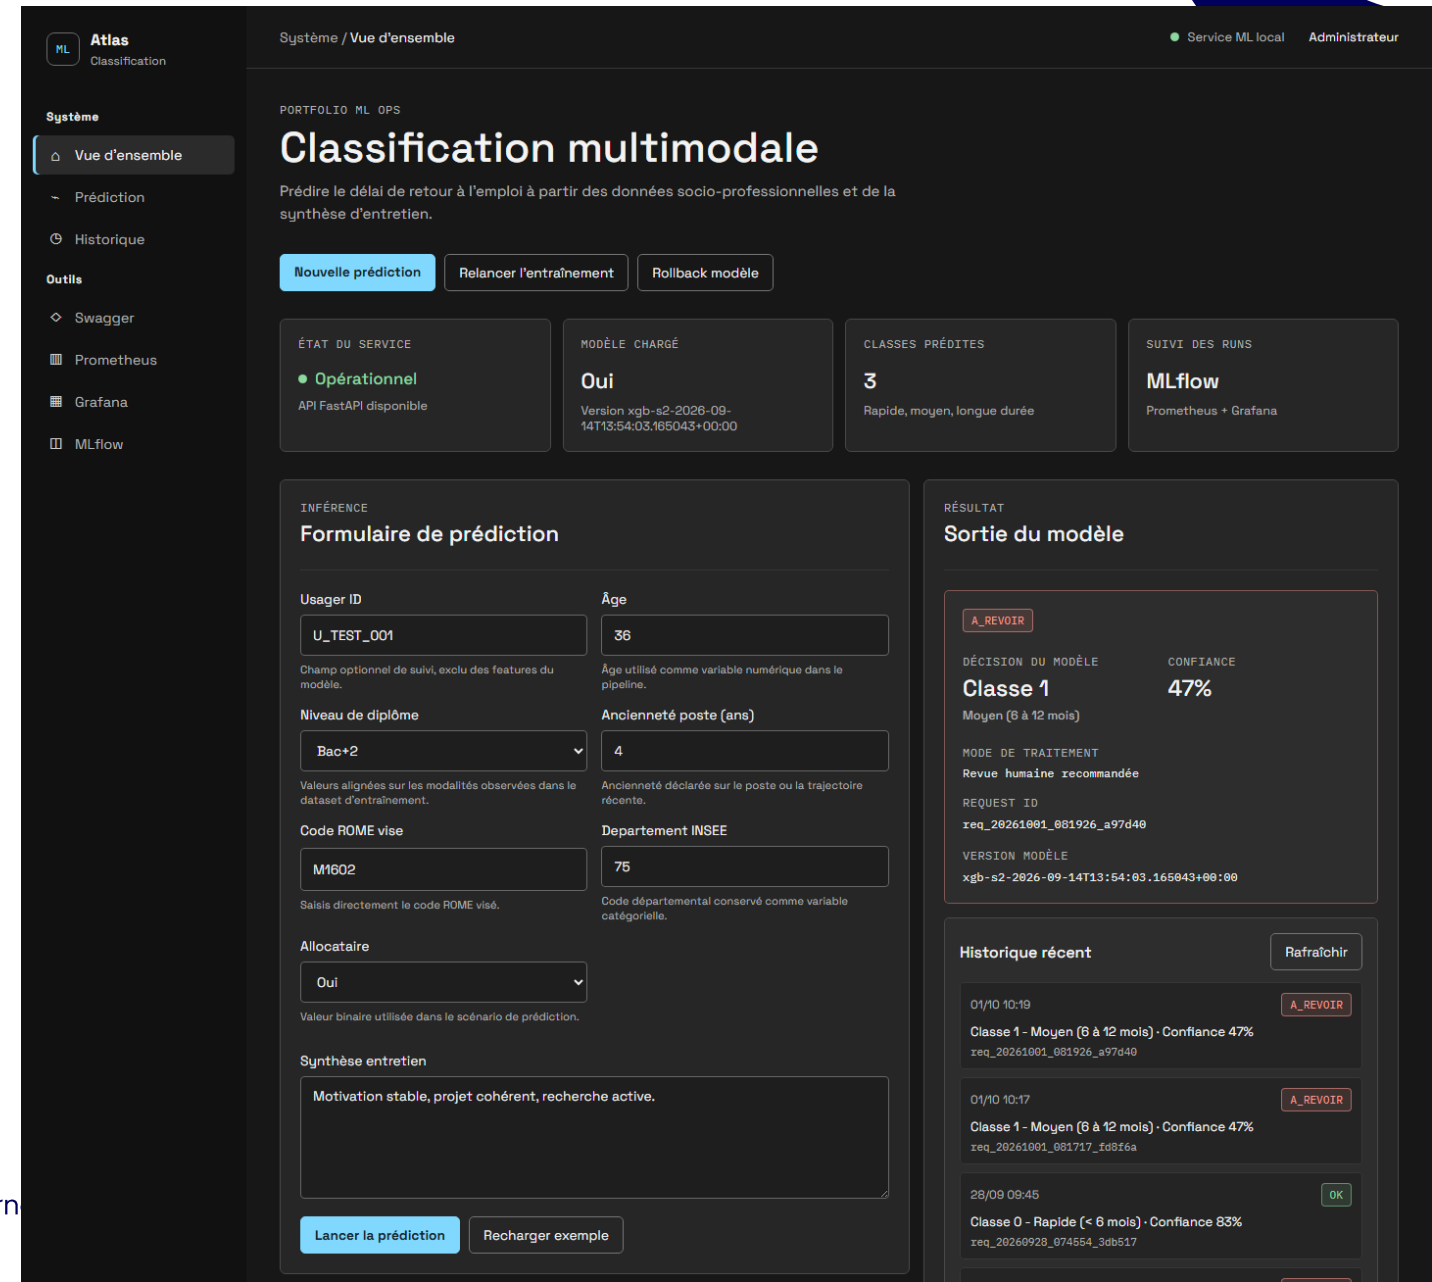
- GET /health
- POST /predict
- POST /retrain
- GET /metrics
- GET /models/history
- POST /rollback
- POST /feedback

- classe prédite
- confiance
- statut ok / a_revoir
- version du modèle
- request_id

L’interface rend l’incertitude visible au conseiller

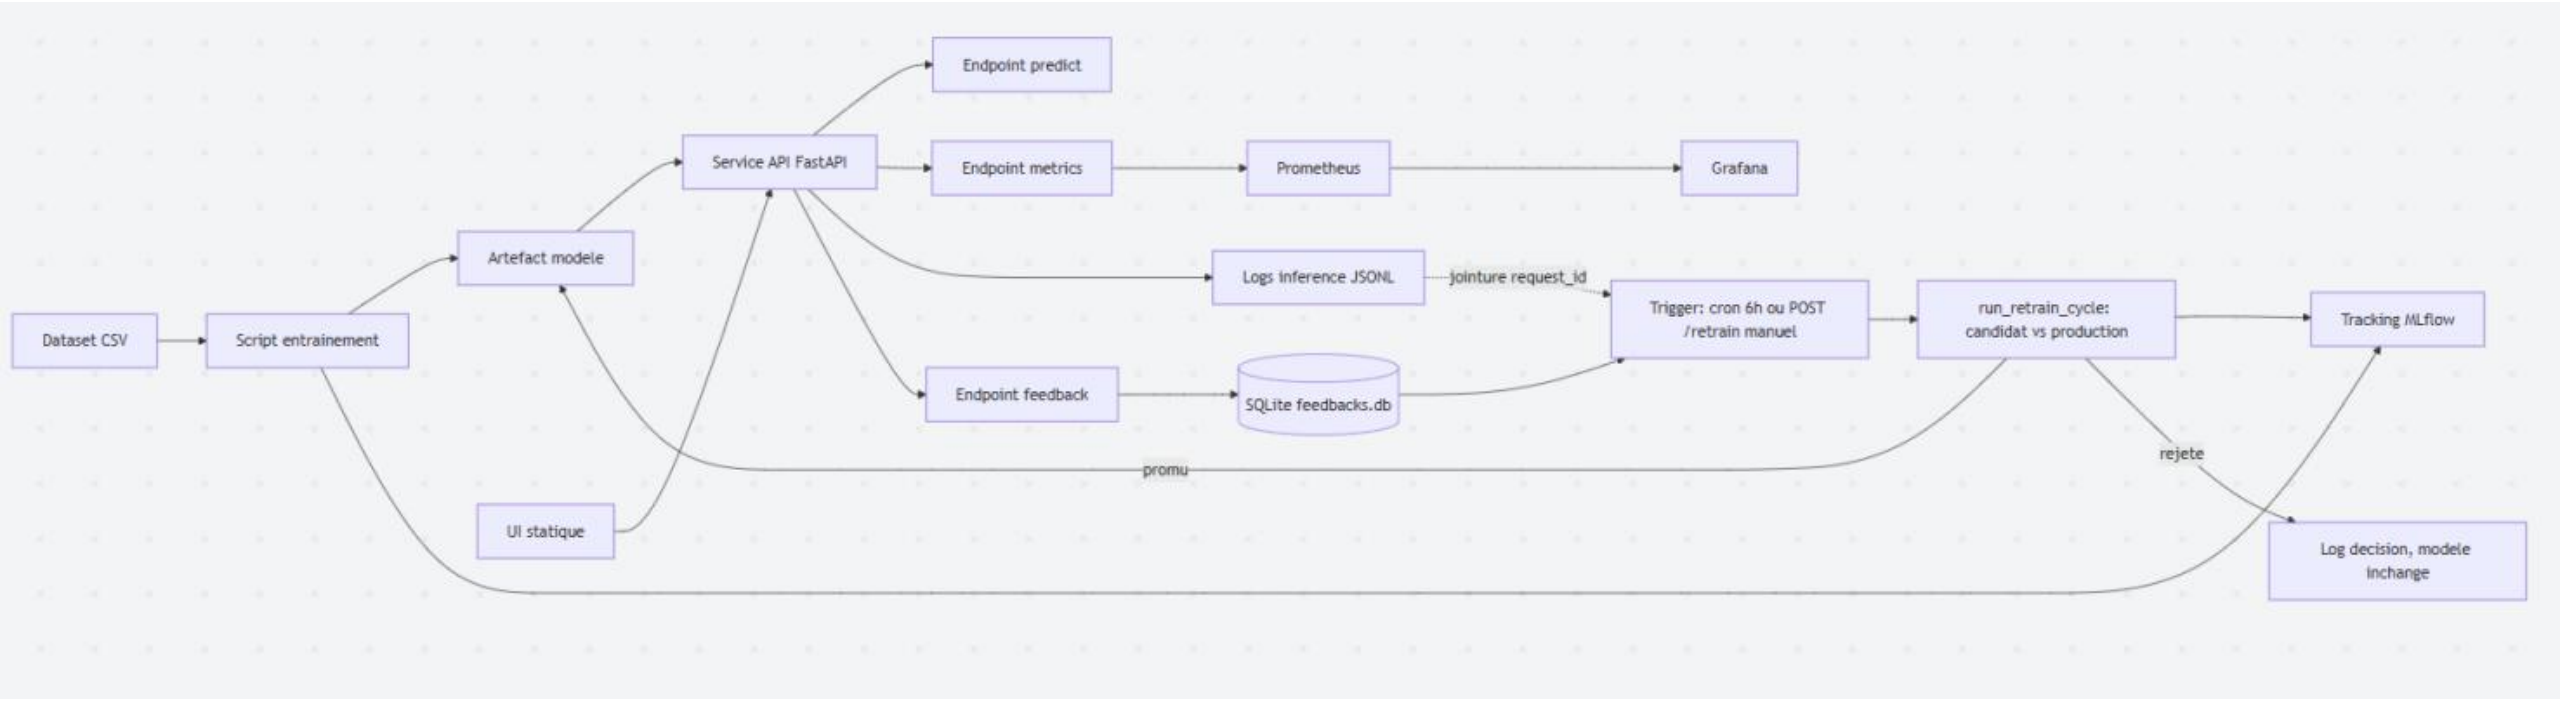
Le résultat inclut la classe, la confiance et le besoin de revue humaine

- Saisir un dossier
- Lancer une prédiction
- Visualiser classe et confiance
- Voir le statut de revue humaine
- Consulter l’historique
- Déclencher retrain ou rollback contrôlé



L’architecture relie usage, observation et réversibilité

Chaque prédiction reste rattachée à un modèle et à une trace



Artefact versionné • logs d’inférence et de retrain • feedback séparé • promotion ou rejet • rollback

Le monitoring distingue santé du service et comportement du modèle

Prometheus et Grafana donnent une vue opérationnelle continue

Activité

- Volume de prédictions
  Classes prédites
  Événements de retrain

Comportement

- Distribution des confiances
  Taux d’abstention

Fiabilité

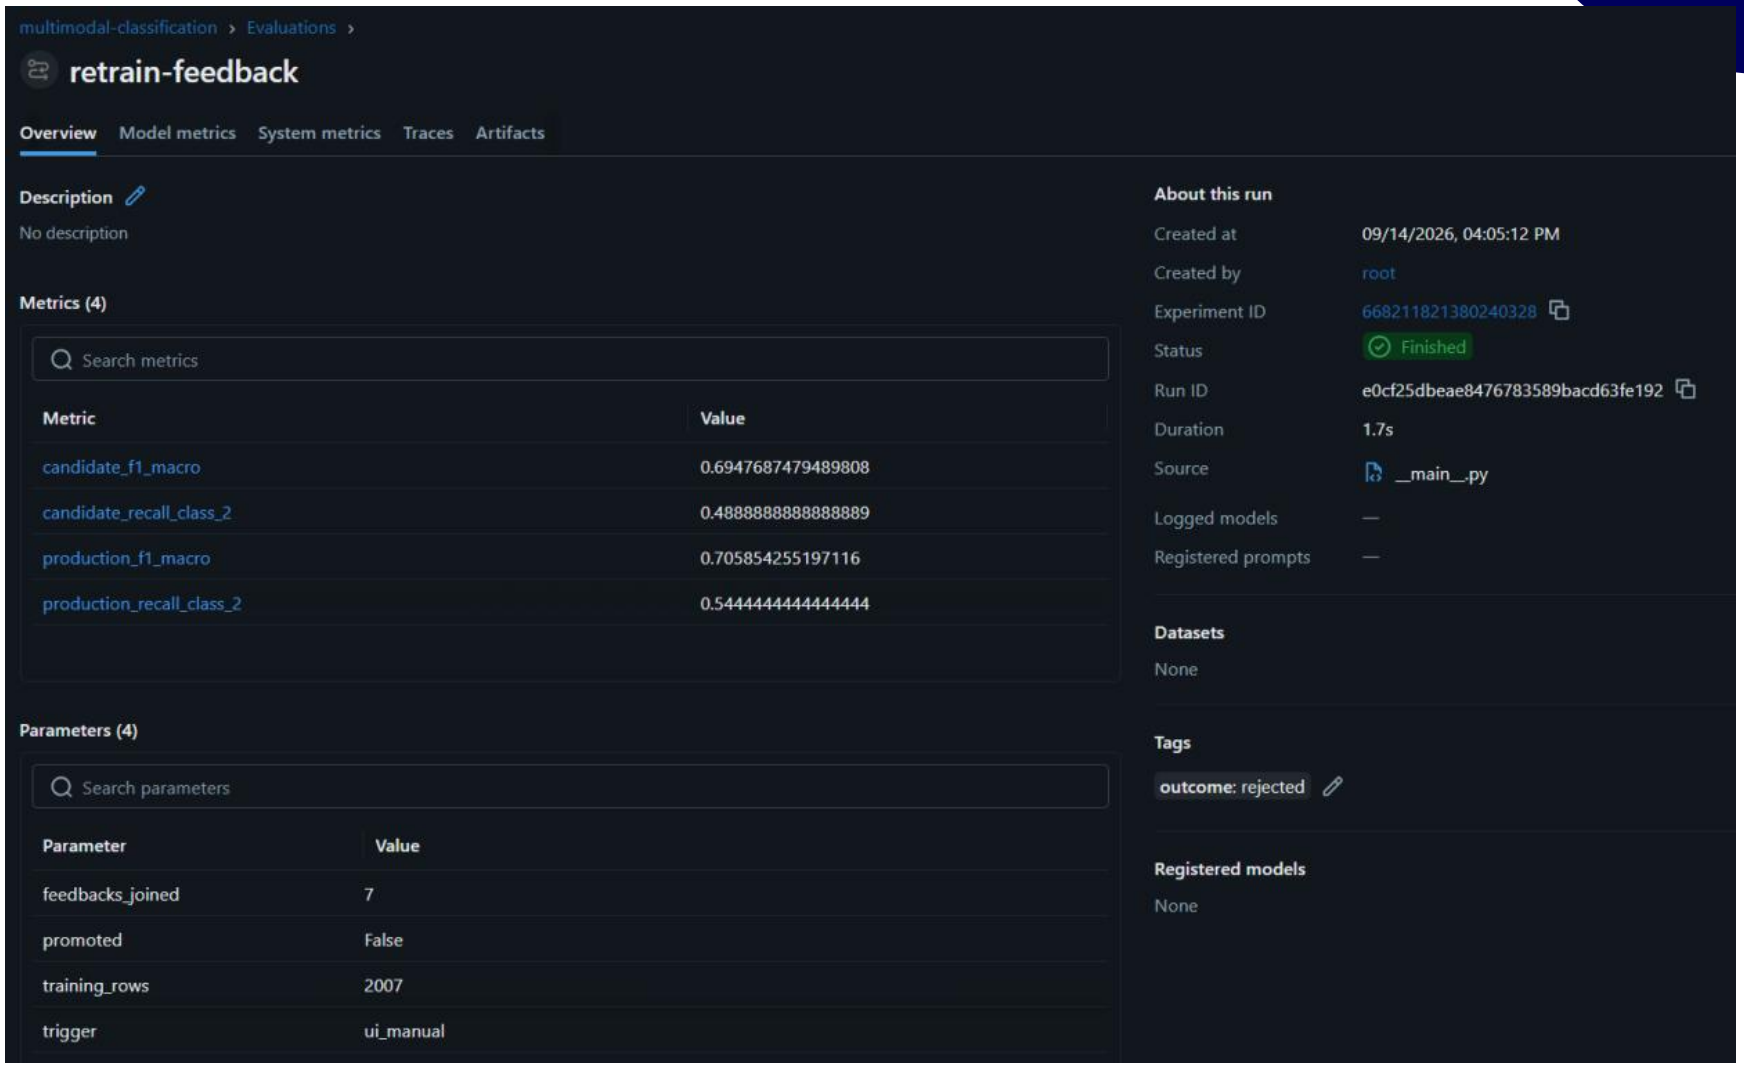
- Latence API
  Erreurs HTTP
  Disponibilité des cibles



MLflow permet de reconstruire l’histoire d’un modèle

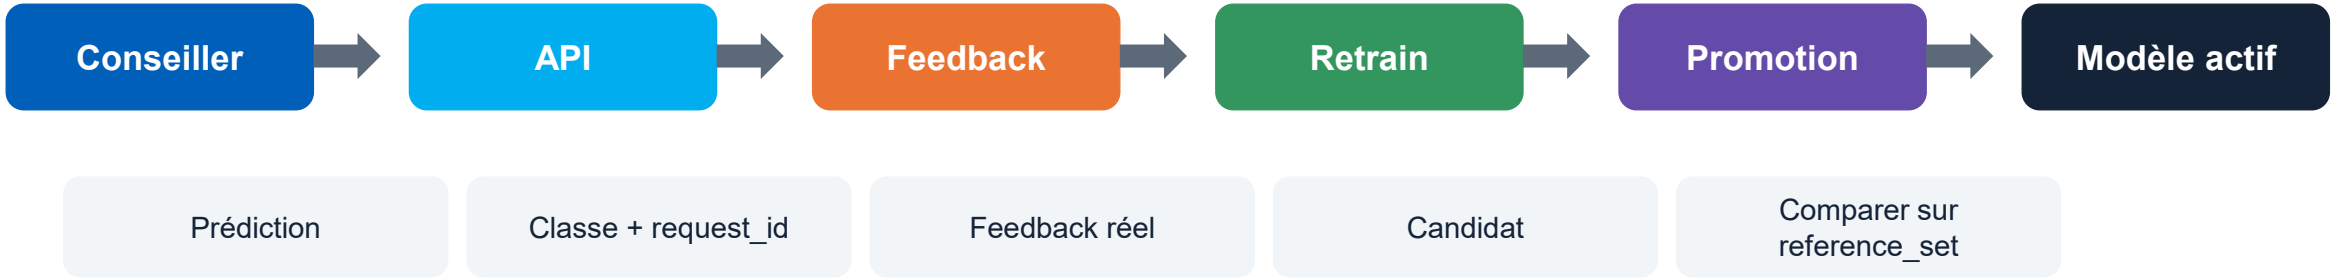
Chaque promotion ou rejet reste explicable

- Paramètres d’entraînement
- Métriques
- Features utilisées
- Artefacts du modèle
- Identifiant du run
- Décision de promotion ou de rejet



La boucle d'amélioration apprend du terrain sans remplacement inconditionnel

La promotion est automatique uniquement lorsque les conditions définies sont satisfaites



Recall classe 2 prioritaire • candidat rejeté = production inchangée • promotion = ancien modèle archivé • rollback disponible

Trigger retrain with feedbacks 2s

```
1  ▶ Run MIN_FB=200
16 ================================================================
17 Début du cycle de réentraînement (cron_feedback) — retrain_20261004_092707_efbe61
18 ================================================================
19 Feedbacks: 6 total, 6 non consommés (seuil: 200)
20 SKIP: 6 feedback(s) non consommé(s) < seuil 200. Rien à faire.
```

Docker

- Docker Compose orchestre :
  - API
  - MLflow
  - Prometheus
  - Grafana
  - Retrain planifié

```
#16 [mlflow] exporting to image
#16 unpacking to docker.io/library/multimodal-classification-mlflow:latest 25.2s done
#16 DONE 73.8s

#15 [retrain-cron] exporting to image
#15 unpacking to docker.io/library/multimodal-classification-retrain-cron:latest 25.2s done
#15 DONE 73.8s

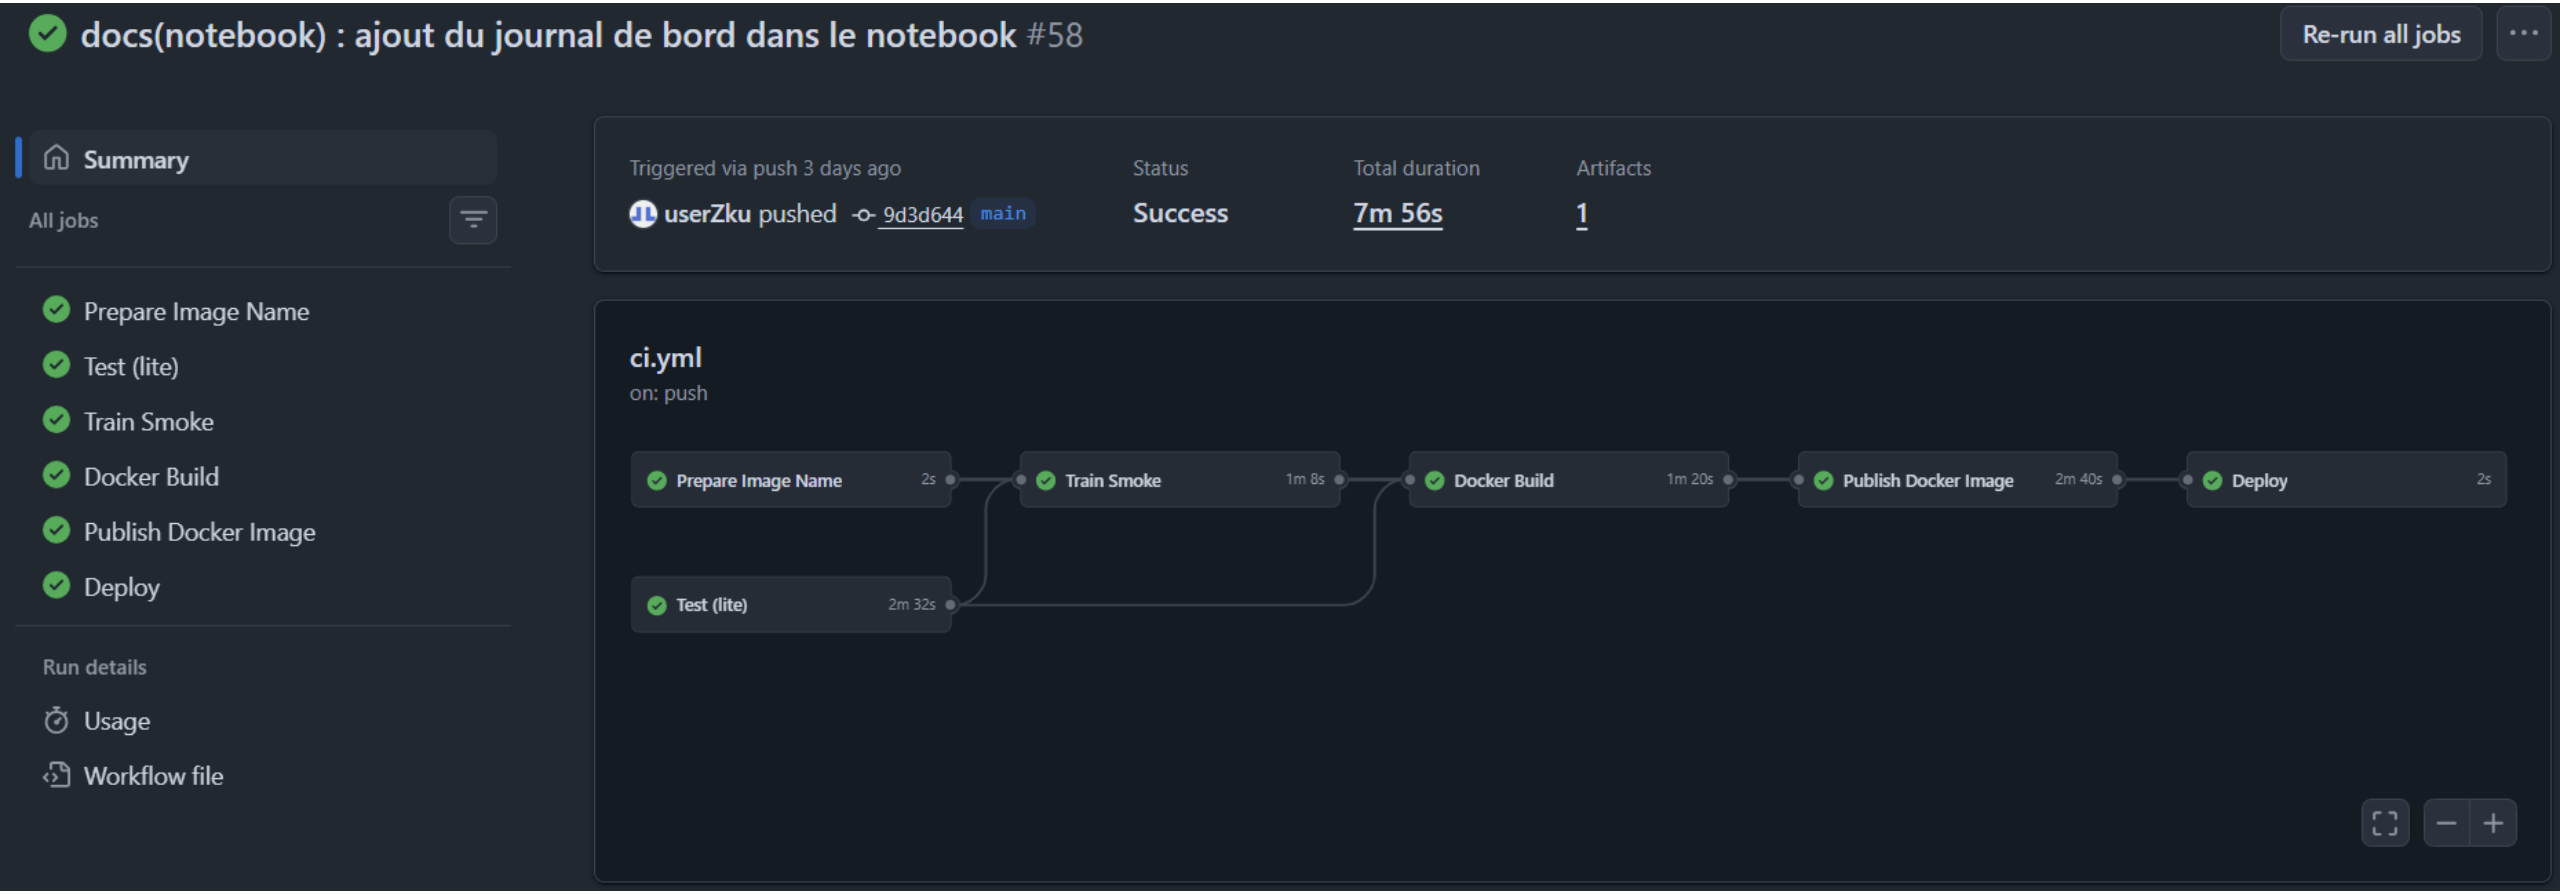
#17 [api] exporting to image
#17 unpacking to docker.io/library/multimodal-classification-api:latest 25.2s done
#17 DONE 73.8s

#19 [api] resolving provenance for metadata file
#19 DONE 0.1s
#18 [mlflow] resolving provenance for metadata file
#18 DONE 0.1s
#20 [retrain-cron] resolving provenance for metadata file
#20 DONE 0.0s
 Image multimodal-classification-mlflow Built
 Image multimodal-classification-retrain-cron Built
 Image multimodal-classification-api Built
```

CI/CD

GitHub Actions automatise :

Tests et qualité → Entraînement smoke → Build Docker → Publication de l'image → Déploiement conditionnel



Les garde-fous réduisent le risque, sans supprimer les limites

Le système reste une aide à la décision soumise à validation humaine

- GARDE-FOUS
- Exclusion de la nationalité
- Identifiant technique séparé
- Journalisation des prédictions
- Revue humaine des cas incertains
- Surveillance des proxys et du texte

- LIMITES
- Dataset de taille modérée
- Classe 2 minoritaire
- Faible diversité des textes
- Capacité réelle des conseillers à valider
- Sécurité API à durcir

Du prototype local à la cible SI

Distinguer ce qui est démontré de ce qui reste à arbitrer avant un usage réel



Hébergement
On-premise ou cloud souverain
→ option à arbitrer

Performance de service
Latence cible à mesurer
→ charge et réseau à tester

Ressources
CPU / RAM = estimations
→ dimensionnement à justifier

Déjà démontré : API, UI, traçabilité, monitoring local. À valider : intégration au SI, sécurité, hébergement, latence et capacité.

CHOIX
S2 sans variable sensible directe, avec règle de revue humaine.

S2 + escalade humaine :

POURQUOI
Un coût de performance mesuré pour un compromis plus défendable.

réelles

À VALIDER

et exploitation.

Atos