Classification multimodale



Le problème métier

Toutes les erreurs ne se valent pas

- Classe 0 | Retour rapide : < 6 mois
- Classe 1 | Retour intermédiaire : 6 à 12 mois
- Classe 2 | Risque longue durée : > 12 mois

ERREUR CRITIQUE

Situation réelle : classe 2
Prédiction : classe 0

Priorité : détecter les cas qui risquent de passer sous le radar

Les données combinent tabulaire, texte et variable sensible

2 500 dossiers • 10 colonnes

Numérique
âge, ancienneté

Catégoriel
diplôme, métier, allocation, géographie

Texte libre
synthèse d'entretien

Sensible
nationalite_hors_ue

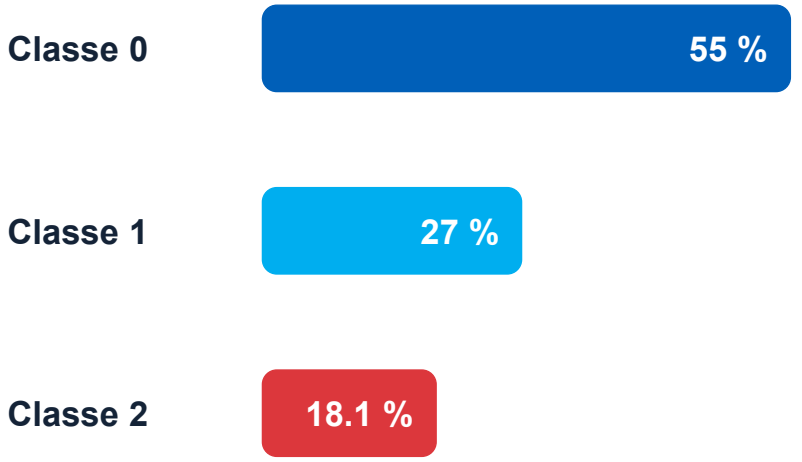
Cible
classe 0, 1 ou 2

Un même dossier alimente plusieurs modalités, mais la variable sensible reste isolée.

L’EDA révèle le déséquilibre et les risques de biais

La qualité des données guide la modélisation

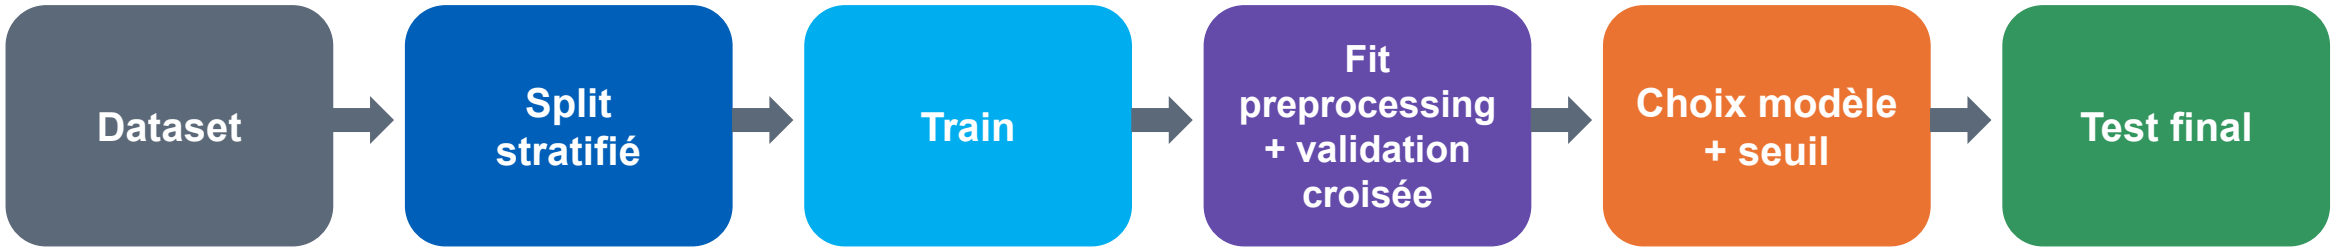
- Classe 2 minoritaire : ≈ 18,1 %
- Valeurs manquantes modérées
- Écarts liés à la nationalité
- Proxys possibles : âge, allocation, géographie, texte
- Texte peu diversifié : risque de sur-apprentissage



À surveiller : proxies et formulations répétitives

Le test reste hors de la boucle de décision

Les transformations et les seuils sont choisis uniquement sur le train



Imputation • encodage ordinal • one-hot encoding • TF-IDF • extraction du département INSEE

Quatre scénarios séparent performance et conformité

S1 est la référence expérimentale, S2 le candidat de production

- S1 — Multimodal complet
  Meilleur score avec toutes les variables
- S2 — Sans variable sensible
  Coût de l’exclusion de la nationalité
- S3 — Texte seul
  Valeur de la synthèse d’entretien
- S4 — Tabulaire seul
  Valeur des données structurées

Une grille de métriques relie score, risque et exploitabilité

Aucune métrique unique ne suffit

Performance globale

- Équilibre entre les trois classes et qualité du classement probabiliste.

Risque métier

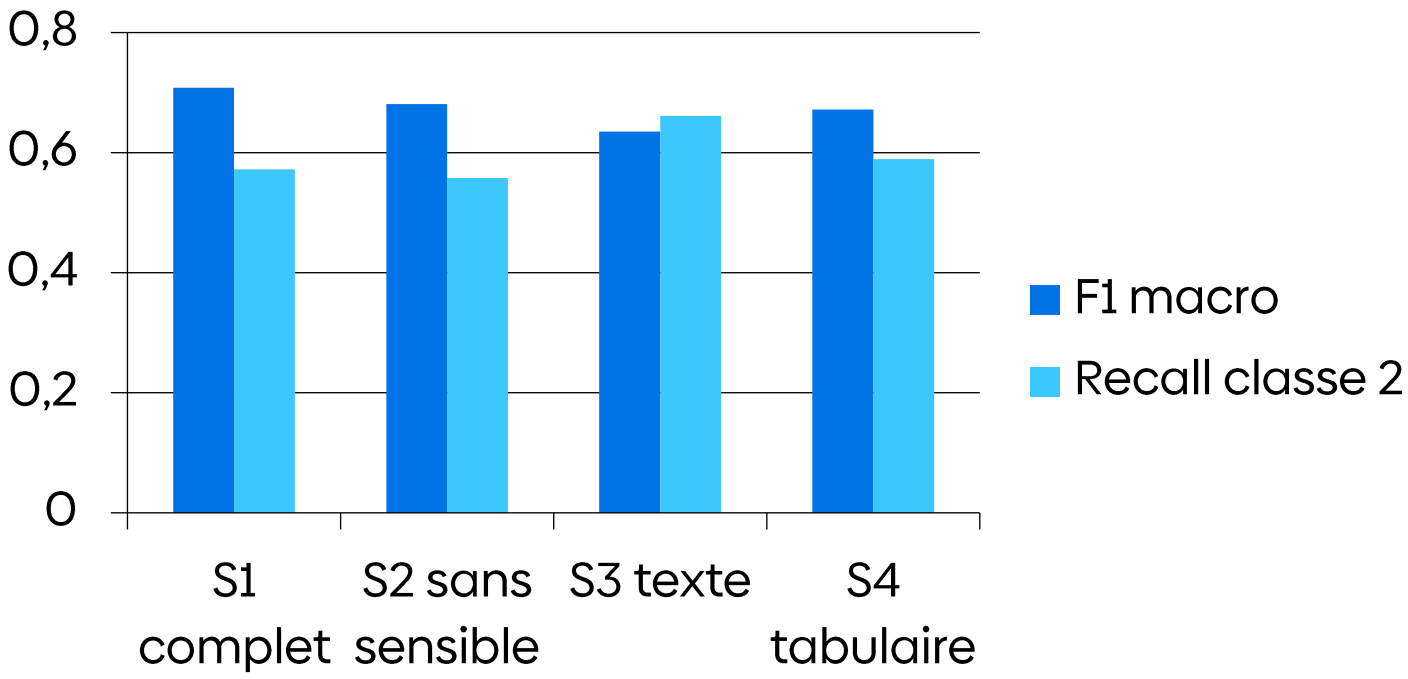
- Capacité à identifier les situations longues et éviter le faux rassurant.

Opérations

- Compatibilité avec un entretien et coût des scénarios.

S1 maximise le score, S2 préserve un compromis défendable

Comparaison en validation croisée et sur le test final



Erreurs 2 → 0 sur test

S1	9
S2	10
S3	12
S4	8

Le prix de la décision éthique est mesuré et assumé

Exclure nationalite_hors_ue réduit légèrement les performances

DÉCISION

- F1 macro : 0,708 → 0,681 | Δ = −0,027
- Recall classe 2 : 0,572 → 0,558 | Δ = −0,014
- « J’accepte une baisse de 0,027 de F1 pour ne pas utiliser un critère de discrimination. »

Un garde-fou métier complète le modèle S2

La règle d’escalade traite le coût asymétrique des erreurs

Prédiction automatique si confiance suffisante → **Statut à_revoir si confiance faible** → **Escalade ciblée si prédiction = 0 et P(classe 2) ≥ 0,20**

Politique combinée = confiance < seuil OU (prédiction = 0 ET P(classe 2) ≥ 0,20)

Le seuil est calibré sans réutiliser le test

Probabilités out-of-fold sur le train

- 5 folds stratifiés
- Chaque observation est prédite par un modèle qui ne l'a pas vue
- Grille de seuils testée sur les prédictions OOF
- Vérification unique sur le test final

- Seuil combiné : 0,70
- Budget d'escalade visé : ≈ 40 %
- Couverture OOF : ≈ 72,5 %
- Test : 8/10 erreurs critiques captées, soit 80 %

Le choix de production privilégie un compromis contrôlable

S2 + XGBoost + escalade humaine

CHOIX

- Exclut la variable sensible directe
- Conserve tabulaire + texte
- Compromis acceptable performance / conformité
- Ajoute une reprise humaine ciblée
- Reste compatible avec un usage API
- S1 demeure une référence expérimentale

L’API transforme le pipeline en contrat de service

FastAPI expose la prédiction, la traçabilité et le cycle de vie

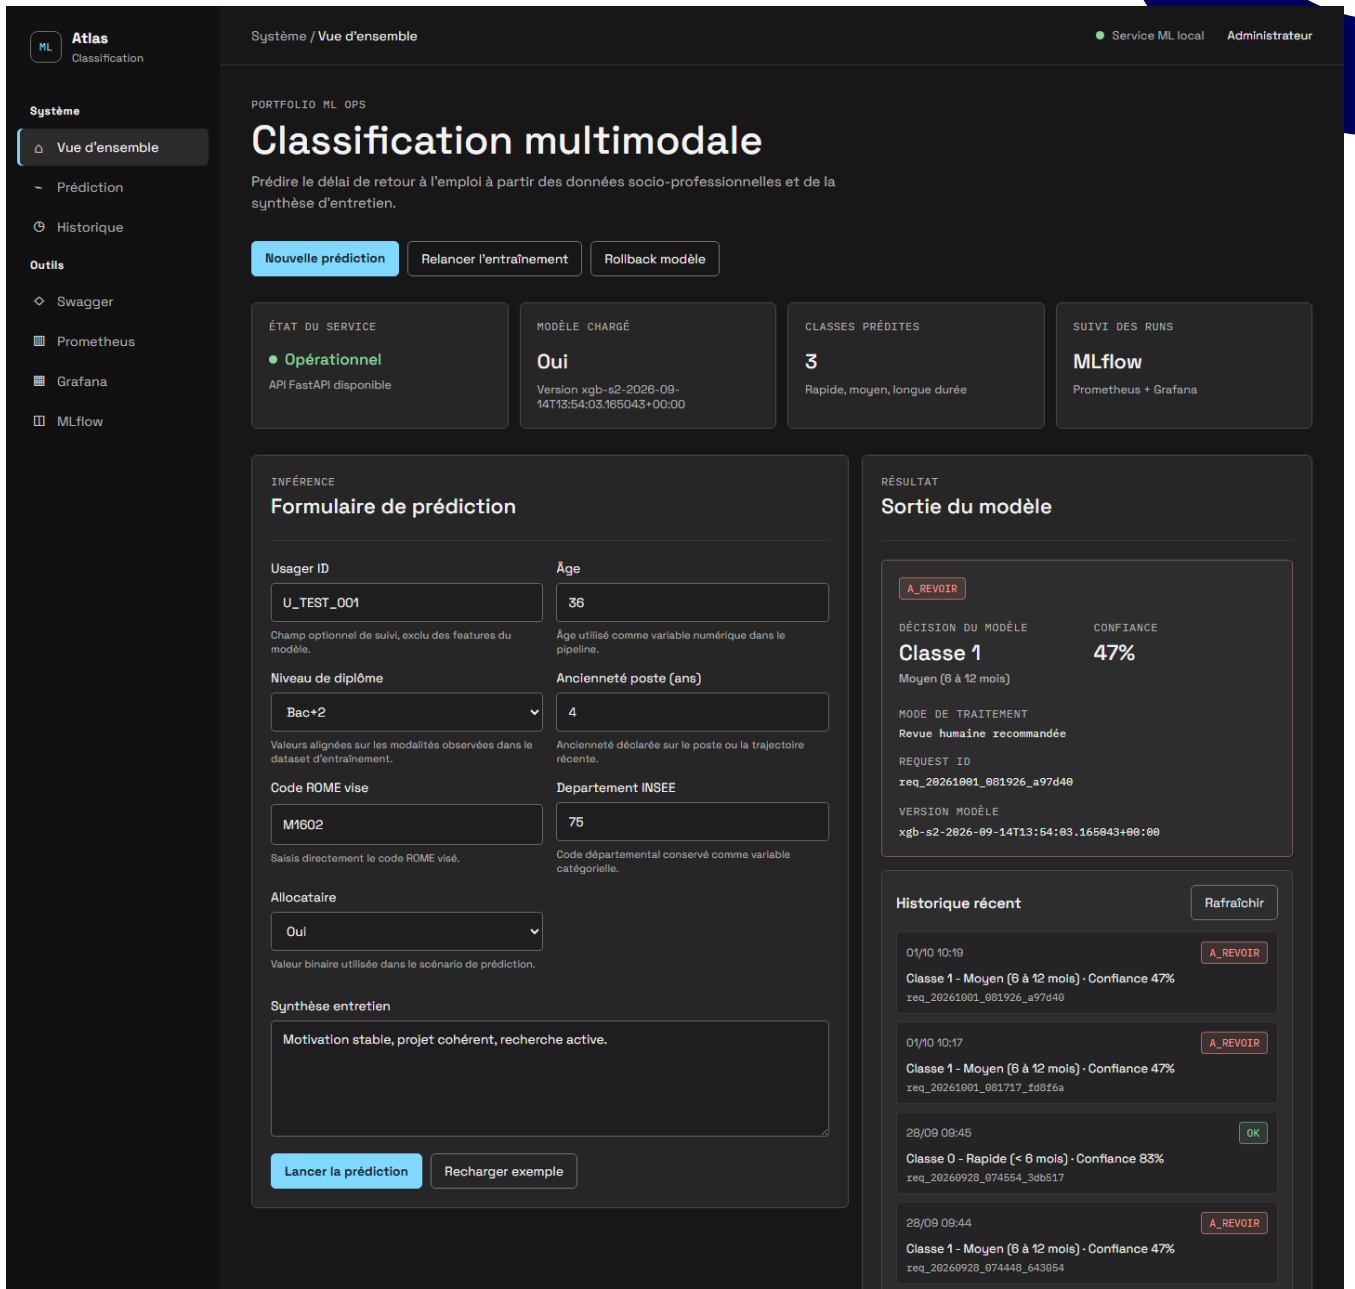
- GET /health
- POST /predict
- POST /retrain
- GET /metrics
- GET /models/history
- POST /rollback
- POST /feedback

- classe prédite
- confiance
- statut ok / a_revoir
- version du modèle
- request_id

L’interface rend l’incertitude visible au conseiller

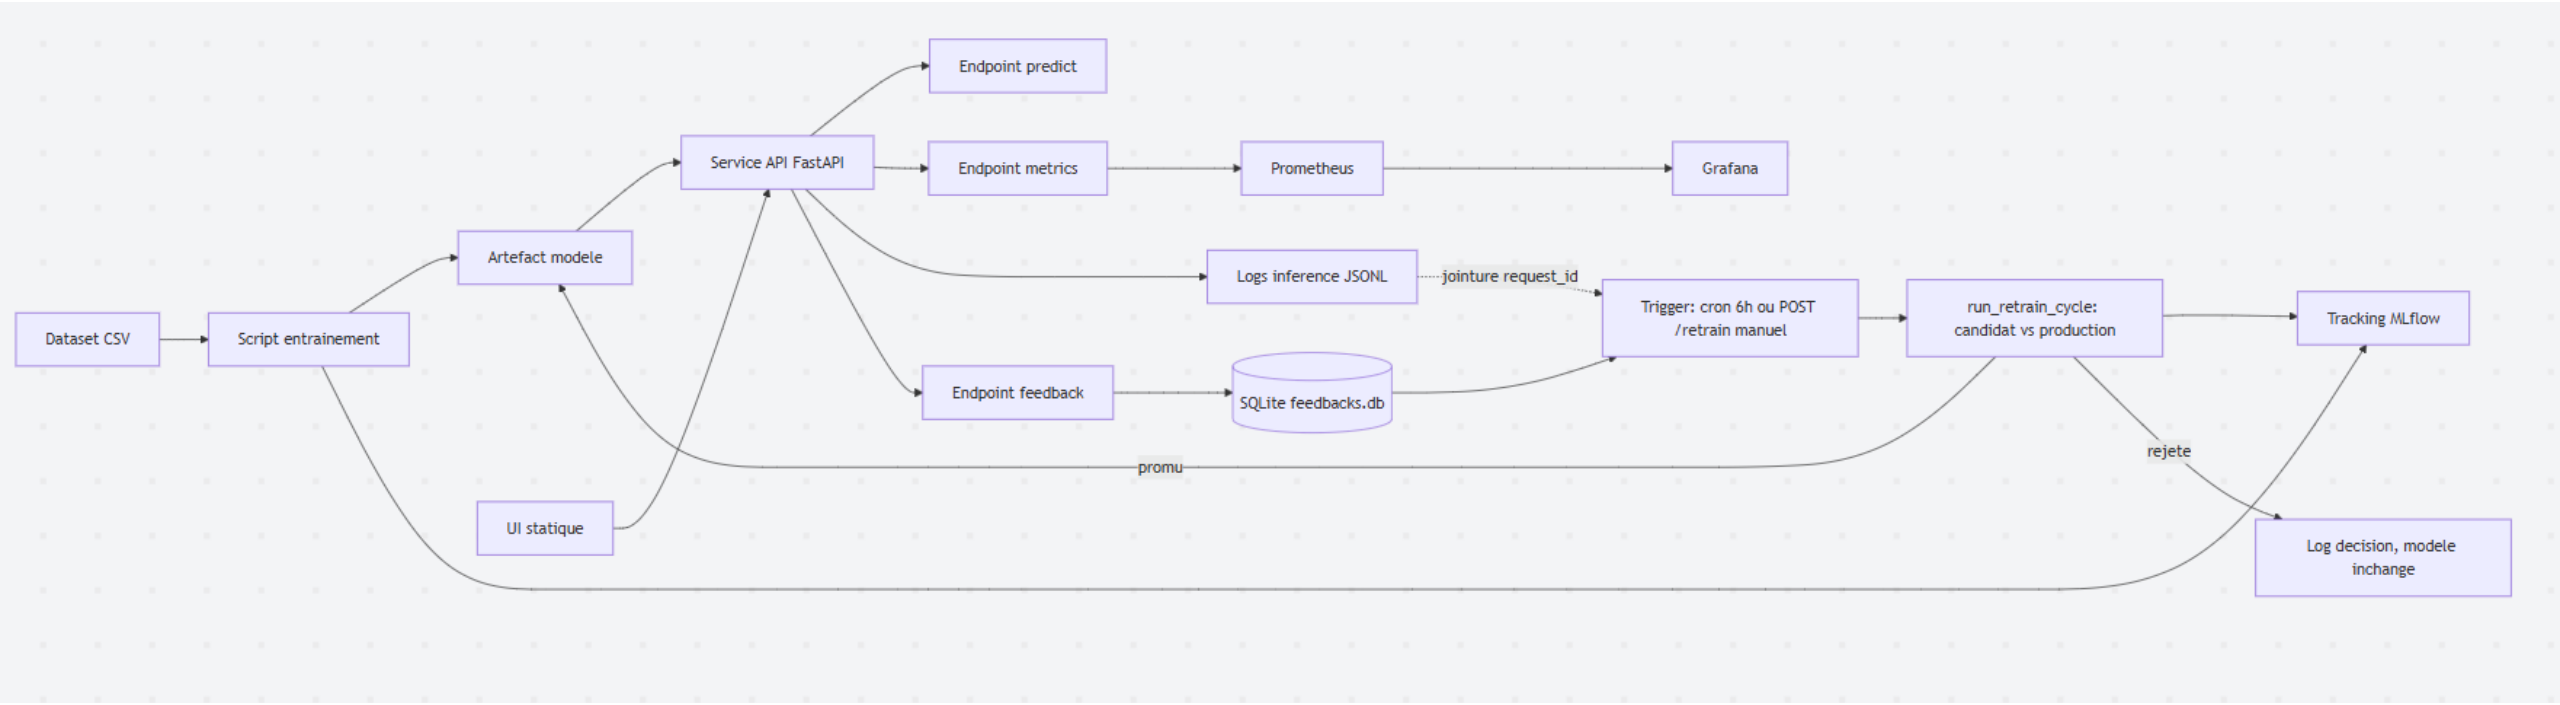
Le résultat inclut la classe, la confiance et le besoin de revue humaine

- Saisir un dossier
- Lancer une prédiction
- Visualiser classe et confiance
- Voir le statut de revue humaine
- Consulter l’historique
- Déclencher retrain ou rollback contrôlé



L’architecture relie usage, observation et réversibilité

Chaque prédiction reste rattachée à un modèle et à une trace



Artefact versionné • logs d’inférence et de retrain • feedback séparé • promotion ou rejet • rollback

Le monitoring distingue santé du service et comportement du modèle

Prometheus et Grafana donnent une vue opérationnelle continue

Activité

- Volume de prédictions
  Classes prédites
  Événements de retrain

Comportement

- Distribution des confiances
  Taux d’abstention

Fiabilité

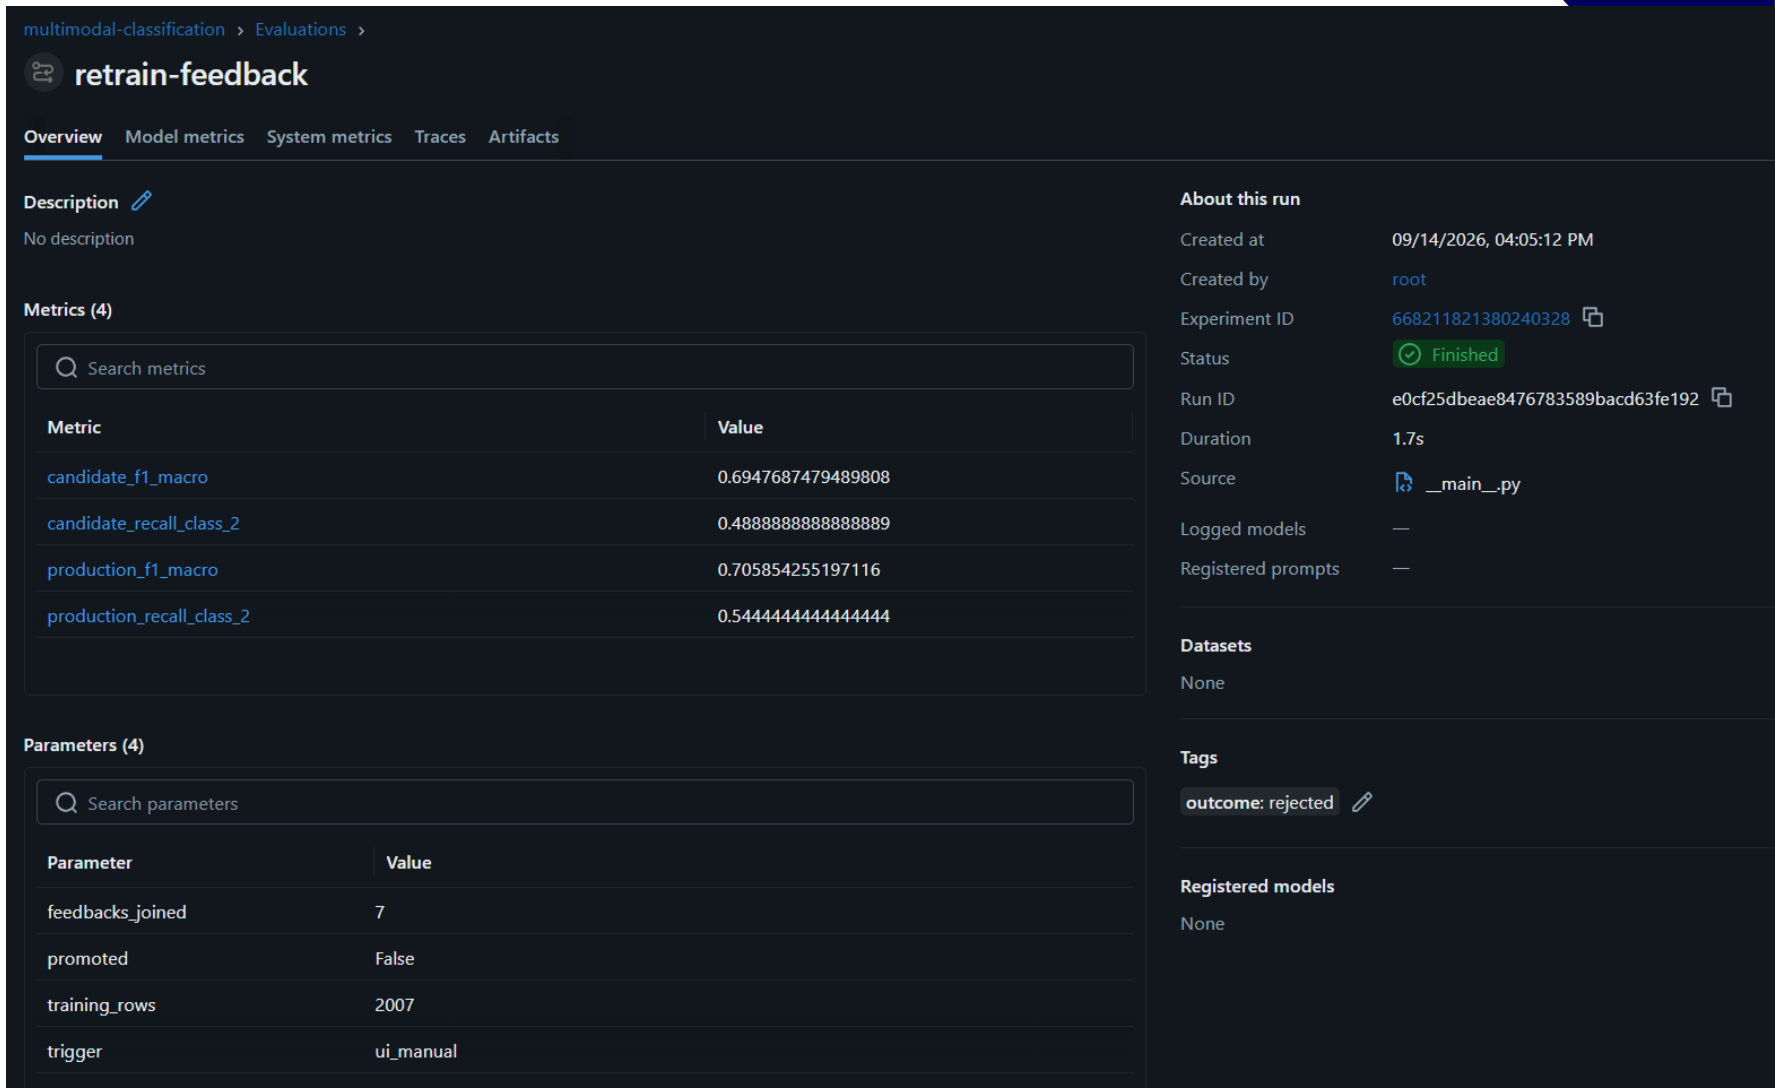
- Latence API
  Erreurs HTTP
  Disponibilité des cibles



MLflow permet de reconstruire l’histoire d’un modèle

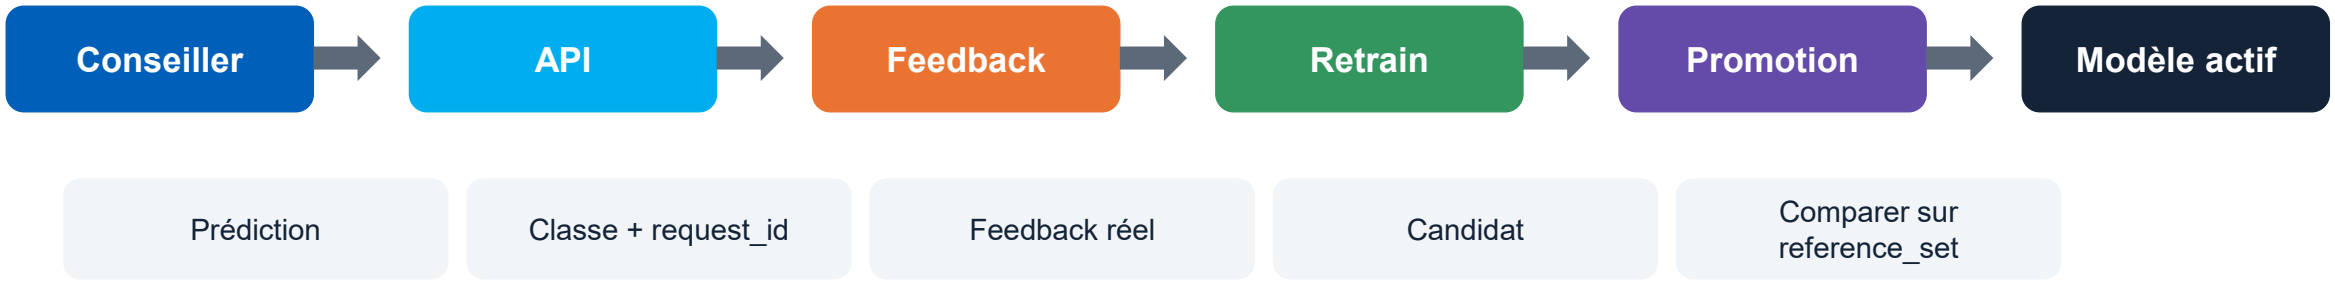
Chaque promotion ou rejet reste explicable

- Paramètres d’entraînement
- Métriques
- Features utilisées
- Artefacts du modèle
- Identifiant du run
- Décision de promotion ou de rejet



La boucle d’amélioration apprend du terrain sans promotion automatique

Feedback, comparaison, promotion et rollback restent contrôlés



Recall classe 2 prioritaire • candidat rejeté = production inchangée • promotion = ancien modèle archivé • rollback disponible

Trigger retrain with feedbacks 2s

```
1  ▶ Run MIN_FB=200
16 ================================================================
17 Début du cycle de réentraînement (cron_feedback) — retrain_20261004_092707_efbe61
18 ================================================================
19 Feedbacks: 6 total, 6 non consommés (seuil: 200)
20 SKIP: 6 feedback(s) non consommé(s) < seuil 200. Rien à faire.
```

Docker

- Docker Compose orchestre :
  - API
  - MLflow
  - Prometheus, Grafana
  - Retrain planifié

```
#16 [mlflow] exporting to image
#16 unpacking to docker.io/library/multimodal-classification-mlflow:latest 25.2s done
#16 DONE 73.8s

#15 [retrain-cron] exporting to image
#15 unpacking to docker.io/library/multimodal-classification-retrain-cron:latest 25.2s done
#15 DONE 73.8s

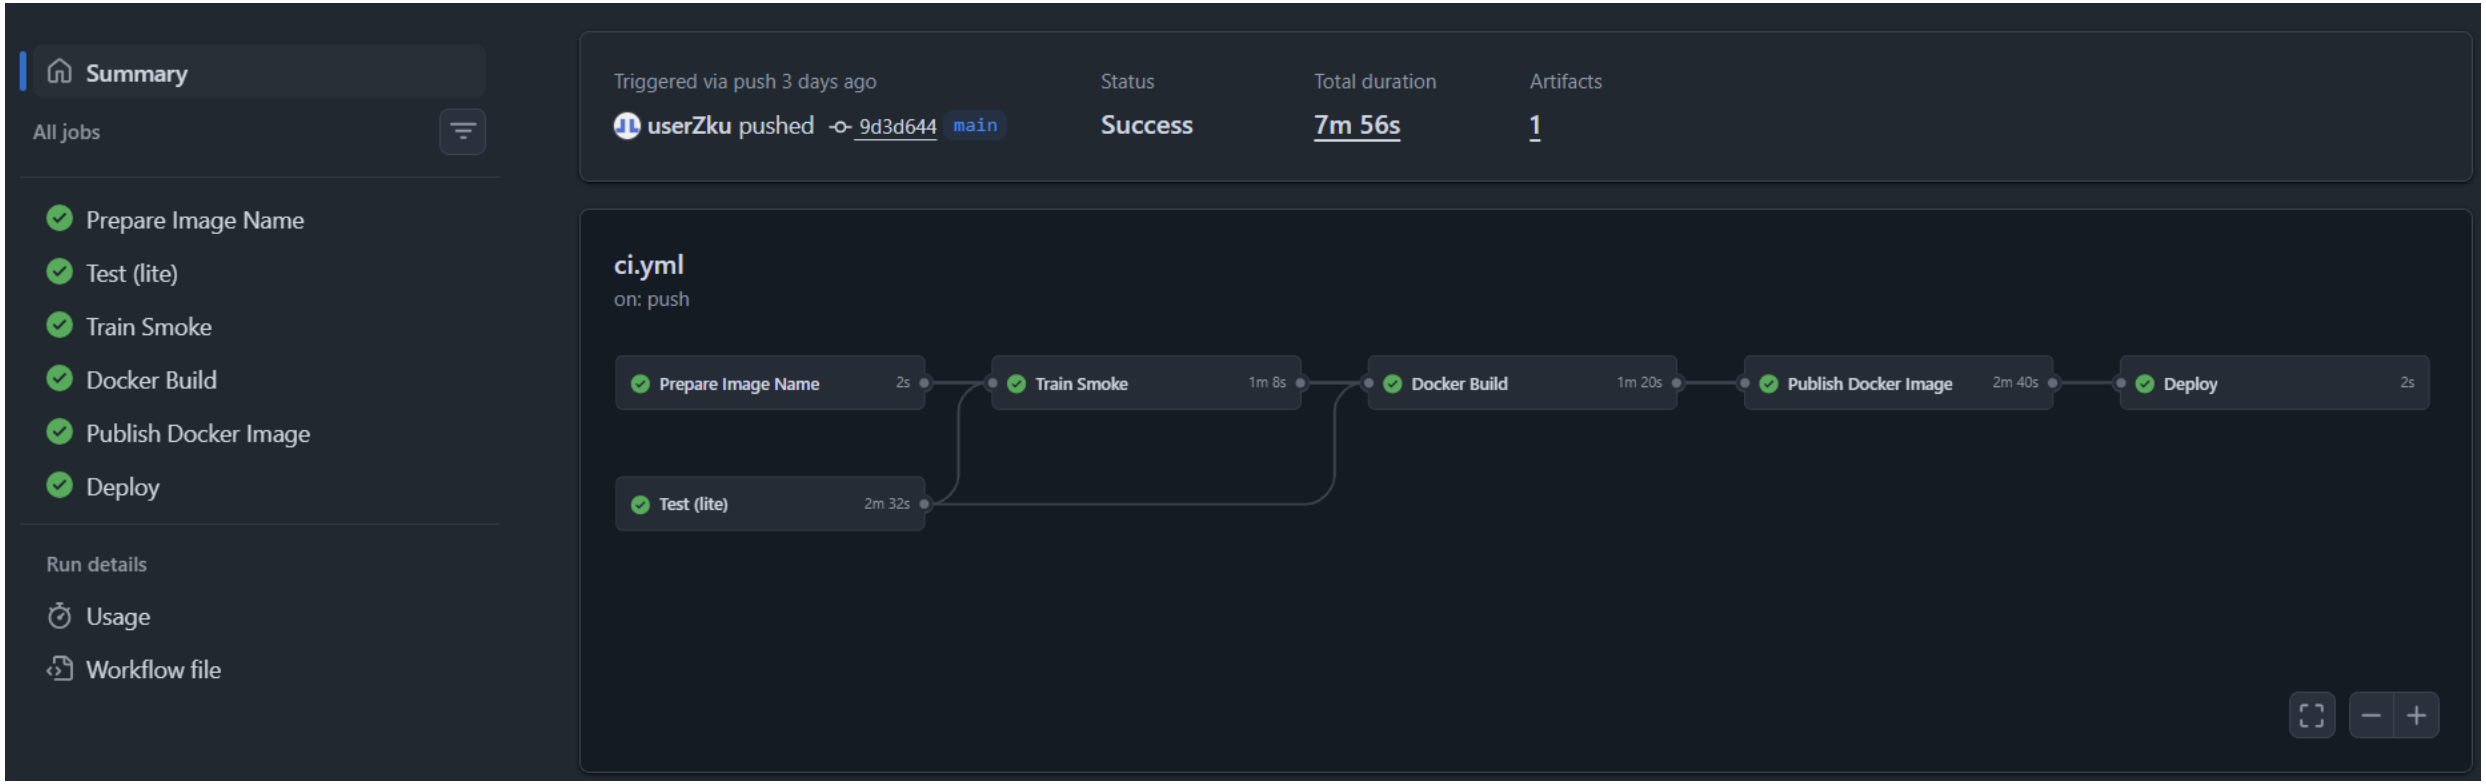
#17 [api] exporting to image
#17 unpacking to docker.io/library/multimodal-classification-api:latest 25.2s done
#17 DONE 73.8s

#19 [api] resolving provenance for metadata file
#19 DONE 0.1s
#18 [mlflow] resolving provenance for metadata file
#18 DONE 0.1s
#20 [retrain-cron] resolving provenance for metadata file
#20 DONE 0.0s
 Image multimodal-classification-mlflow Built
 Image multimodal-classification-retrain-cron Built
 Image multimodal-classification-api Built
```

CI/CD

GitHub Actions automatise :

Tests et qualité → Entraînement smoke → Build Docker → Publication de l'image → Déploiement conditionnel



Docker et CI/CD rendent la chaîne répétable

Le livrable global

- Docker Compose orchestre :
  - API
  - MLflow
  - Prometheus
  - Grafana
  - Retrain planifié

- GitHub Actions automatise :
  - Tests et qualité
  - Entraînement smoke
  - Build Docker
  - Publication de l’image
  - Déploiement conditionnel

Les garde-fous réduisent le risque, sans supprimer les limites

Le système reste une aide à la décision soumise à validation humaine

GARDE-FOUS

- Exclusion de la nationalité
- Identifiant technique séparé
- Journalisation des prédictions
- Revue humaine des cas incertains
- Surveillance des proxys et du texte

LIMITES

- Dataset de taille modérée
- Classe 2 minoritaire
- Faible diversité des textes
- Capacité réelle des conseillers à valider
- Sécurité API à durcir

Le projet livre une chaîne complète et gouvernable

Modèle, service, observation et décision éthique sont réunis

- Notebook exécutable
- 4 scénarios comparés
- Choix S2 argumenté
- Réduction des erreurs critiques
- API FastAPI
- UI de démonstration
- Docker Compose
- MLflow
- Prometheus + Grafana
- Feedback / retrain / promotion / rollback
- CI/CD GitHub Actions
- Documentation RGPD et décisionnelle

Un système d’aide à la décision qui rend visibles ses compromis, ses limites et les conditions de son usage responsable.

Traçable • observable • réversible • soumis à validation humaine

Questions